B.D.A.I 9주 부트캠프: 심화반 FINDA 5팀

시장 데이터를 통한 상장폐지 예측

팀원 : 김민규, 김요은, 박찬규, 이호준, 정환희

목차

1 문제정의

2 시장조사

3 데이터 수집

4 파생변수 가공

5 모델 구성 및 성능 평가

6 EDA

7 재무데이터 모델 구축

8 결과 및 시사점

1 문제정의

현존하는 시장의 기업 건전성평가 모델은 분기별 데이터로 산출되어 민첩한 스크리닝이 어렵다.

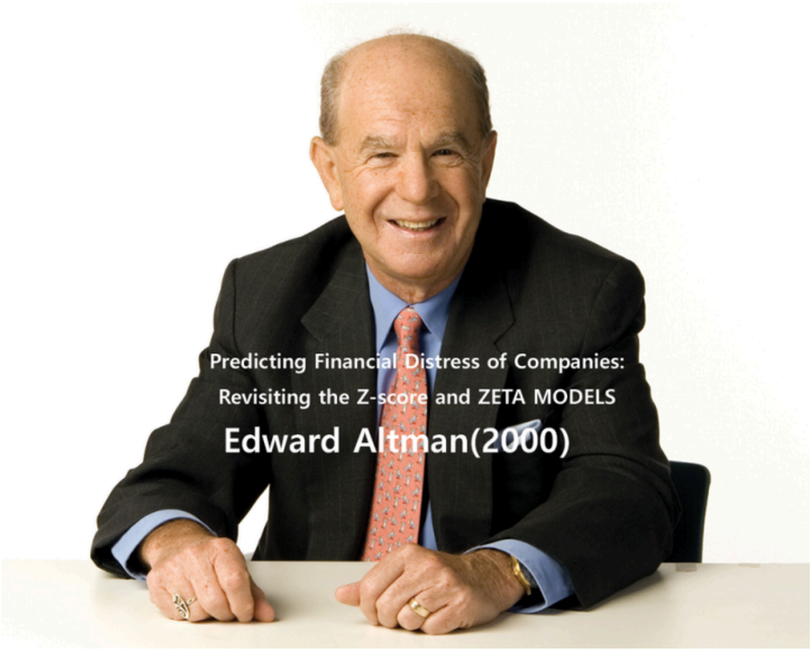

Joseph Piotroski

F-Score

시장(가격·거래량)에서 더 빨리 움직이는 신호로 건전성을 실시간에 가깝게 스크리닝해보자

2 시장조사

신호로 인식 할 수 있는 데이터에 무엇이 있는가?

SHORT-TERM

주가데이터

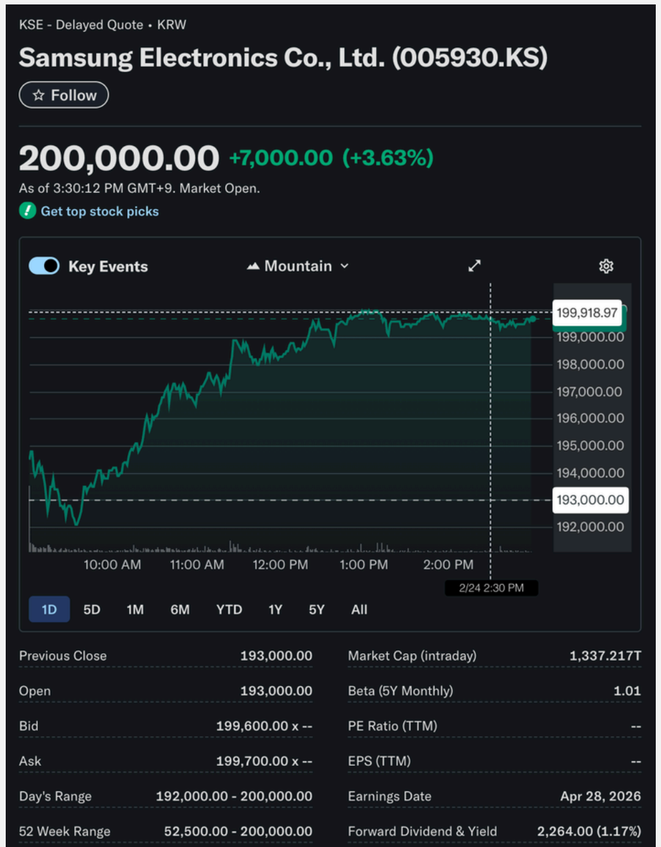

LONG-TERM

재무데이터

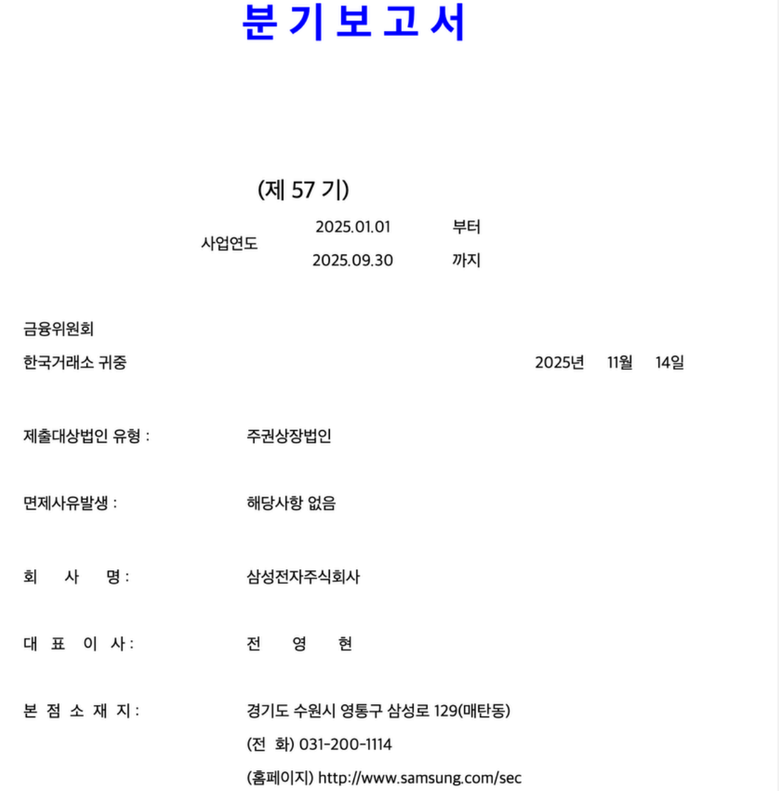

분 기 보 고 서

(제 57 기)

사업연도 2025.01.01 부터 2025.09.30 까지

금융위원회
한국거래소 귀중 2025년 11월 14일

제출대상법인 유형 : 주권상장법인

면제사유발생 : 해당사항 없음

회 사 명 : 삼성전자주식회사

대 표 이 사 : 전 영 현

본 점 소 재 지 : 경기도 수원시 영통구 삼성로 129(매탄동)
(전 화) 031-200-1114
(홈페이지) http://www.samsung.com/sec

3 데이터 수집

- **데이터 소스:** yahoofinance
- **기간:** 2019 ~ 2025 (7년)
- **기본 피쳐:** 기본 주가 정보(OHLCV)
- **추가 피쳐**: 주가 기반 파생변수

프로세스

1. Dart+fdr제공 종목 데이터 통일
2. 종목데이터 내 종목 코드 기반 데이터 수집

총 종목 수 : 3094

```
# 1) final_df.csv 로드 – 데이터 통일 분
final_df = pd.read_csv("final_df.csv", dtype={"corp_code": "string", "stock_code": "string"})

# corp_code 유효 + stock_code 유효한 종목만
sample = final_df[
    final_df["corp_code"].str.match(r"^\d{8}$", na=False) &
    final_df["stock_code"].str.match(r"^\d{6}$", na=False)
].copy()


START = "2019-01-01"
END   = "2025-12-31"
```

4 파생변수 가공

단일 지표로는 리스크를 놓친다.

파생변수를 통해 실시간성과 추세 챙기기

수익률·변동성

ret_1q :
전 분기 대비 주가가 몇 % 올랐는지/떨어졌는지
logret_1q :
수익률을 통계적으로 쓰기 쉽게 바꾼 값 (모델용)
cumret_4q :
최근 1년 동안 전체적으로 상승했는지 하락했는지
down_gap_q :
한 분기 동안 -10% 이상 급락했는지 (급락 신호)
vol_4q :
최근 1년간 주가 흔들림 정도
vol_8q :
최근 2년간 주가 흔들림 정도
max_drawdown_4q :
최근 1년 동안 고점 대비 얼마나 크게 떨어졌는지

추세·모멘텀

ma4 :
최근 1년 평균 주가
ma8 :
최근 2년 평균 주가
ma4_ratio :
현재 주가가 평균보다 위인지 아래인지
ma_cross_4_8 :
단기 평균이 장기 평균보다 아래인지 (하락 추세 신호)
mom_4q :
1년 전보다 지금 주가가 얼마나 변했는지
intraquarter_range :
한 분기 동안 가격이 얼마나 크게 출렁였는지

거래량·리스크

vol_z_4q :
이번 분기 거래량이 평소보다 비정상적으로 많거나 적은지
vol_drop_ratio_4q :
거래량이 평균보다 줄었는지 (유동성 감소)
crash_count_4q :
최근 1년 동안 급락한 분기 횟수
down_streak_1q :
몇 분기째 연속 하락 중인지
down_streak_4q_max :
최근 1년 중 가장 길었던 연속 하락 기간
vol_mean_decline_q :
거래량이 장기적으로 감소하는 추세인지

5 모델 구성: 감사의견 예측

모델 선정 : RandomForest

1. 감사 데이터 불균형(Imbalance) 해결
2. 확률 기반의 커스텀 가중치 적용 가능

데이터 전처리 방

1. Target들을 4개의 클래스로 정의.
2. 클래스별 가중치(boost_array)를 곱함.

모델 목표

감사의견 데이터 분석을 통해
기업의 '비적정' 감사의견을
미리 예측한다.

사용한 데이터

X 데이터 : 시장 데이터(주가)
Y 데이터 : 감사의견 데이터

모델 평가

1. 클래스들의 Recall(재현율)성능 극대화
2. 모델이 '비적정'이라고 맞추는 것에 집중

5 모델 설계 과정

① 데이터 업로드(Loading)

- train.csv(학습용)와 test.csv(검증용) 파일을 업로드.
- 기업들의 마켓 데이터, '감사의견'이 담긴 데이터프레임이 생성.

② 데이터 전처리 (Preprocessing)

- **라벨 인코딩(Label Encoding):** '상장폐지 여부'를 0과 1로 치환.
- **타겟 변수 설정:** 예측 목표인 '감사의견'을 4개의 클래스로 분류.
  - 0(적정), 1(한정), 2(기타), 3(부적정/의견거절)
- **데이터 정제:** 종목코드 같은 학습에 도움이 되지 않는 식별값 삭제.

③ 데이터 불균형 해소(Resampling)

- **오버샘플링:** 적은 클래스(1, 2, 3번 의견) 데이터를 인위적으로 복제.
- **데이터 증폭:** 가장 많은 '적정(0)' 데이터 양 기준, 나머지 1.2배로 증가.
  - 모델이 위험 신호에 민감하게 반응하도록 설계.

④ 모델 설계 및 학습 (Model Training)

- **앙상블 기법:** 의사결정 나무(n_estimators=200)가 데이터를 분석.
- **가중치 밸런스:** class_weight='balanced' 옵션을 적용.
  - 데이터 양이 적은 클래스에 더 높은 중요도를 부여.

⑤ 확률 기반의 결과 보정 (Recall Boosting)

모델이 예측한 결과값에서 위험 케이스에 가중치를 곱해 최종 판정한다.

- **확률 추출:** 모델이 특정 기업을 보고 각 의견(0~3)일 확률을 계산.
- **배수 적용 (Boost Array):** 계산된 확률에 미리 정해둔 배수를 곱함.
  - 실제 확률이 낮더라도 강력한 경고를 보내도록 유도.
- **최종 결정:** 가중치가 곱해진 값 중 가장 높은 것을 최종 선택.
  - '위험을 놓치지 않는 것(Recall)'에 초점.

5 모델의 전처리 과정

범주형 변수의 수치화

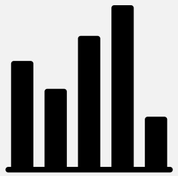

텍스트 데이터를 숫자로 변환

상장폐지 여부:
'상장'은 0, '상장폐지'는 1로 매핑하여 피처를 재생성한다.

타겟 변수 생성 및 라벨링 (Target Labeling)

'감사의견'을 4개 클래스로 재분류

4개의 클래스:

- 0 (적정): 감사의견이 정상적인 상태
- 1 (한정): 주의가 필요한 케이스
- 2 (기타/확인필요): 판단이 필요한 상태
- 3 (부적정/의견거절): 부정적 감사의견 상태

불필요한 피처 제거 (Feature Selection)

노이즈 혹은 예측에 관련이 없는 정보 삭제

삭제 대상:
주식 코드(stock_code), 기업명(Name), 분기(quarter)와 같은 식별값들을 제외.
중복 및 정답지 제거:
'상장폐지 여부' 원본 텍스트 컬럼, 정답지인 '감사의견' 컬럼 삭제.

데이터 불균형 해소 (Resampling)

소수 데이터를 인위적으로 늘려 학습 능력을 강화

기준 설정:
가장 데이터가 많은 '적정'을 기준으로 설정.
소수 클래스 증폭:
'한정', '기타', '부적정' 데이터를 '적정' 데이터의 1.2배가 되도록 중복 추출(Resample).
소수 클래스를 다수 클래스보다 많이 하여, 모델이 위험 신호을 강하게 학습

5 모델 성능 평가

모델 성능

구분	Precision (정밀도)	Recall (재현율)	F1-Score
적정	0	0.09	0.01
한정	0.5	1	0.67
기타/의견필요	0.99	0.87	0.93
부적정 or 의견거절	0.17	0.87	0.28
Accuracy (정확도)			0.87

결과 분석 요약

1. 위험 포착 능력(Recall) 극대화:

- 모델 설계 의도대로 '부적정 혹은 의견거절' 클래스의 Recall이 0.87로 매우 높게 나타난다.
- 실제 부적정 기업 23건 중 20건을 맞추었다.

2. 데이터 불균형의 영향:

- '기타/의견필요' 데이터가 전체의 대부분(99%)을 차지하는 불균형한 구조이다.
- 모델의 가중치 조절을 통해 소수 클래스인 '한정'(1.00)과 '부적정'(0.87)의 검출력을 높였다.

3. 트레이드 오프(Trade - off):

- 재현율(Recall)을 강제로 높이다 보니, **'적정'**의견을 맞추는 정밀도(precision)에서 0에 가까운 수치가 나타나게 되었다.
- 이는 "안전한 기업을 위험하다고 오판을 해도, 위험한 기업을 제대로 판별하겠다는 의도를 반영하였다.

6 EDA : 관리종목 제외 이유

<관리종목 여부별 2분기 후 상장폐지 비율>

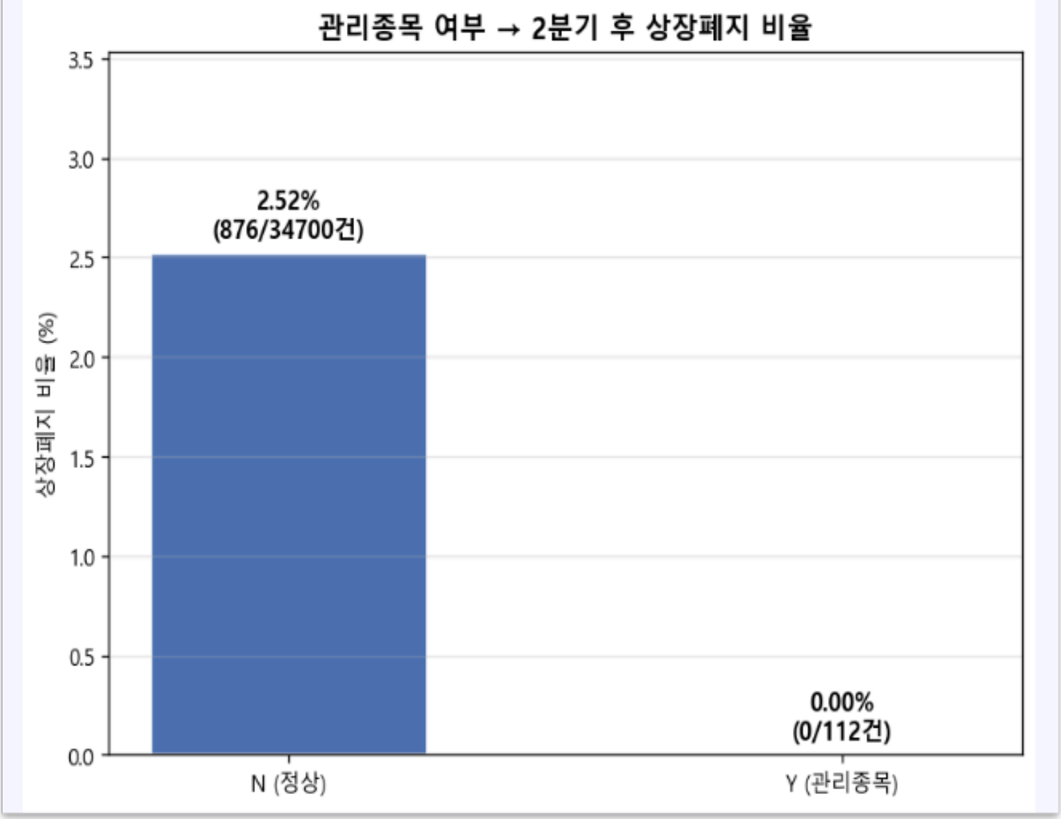

1. 상장폐지 예측 시점 불일치

2. 이후 결과를 확인할 기간 부족

3. 조기 예측 변수로 부적절

---> 감사의견 중심 모델 재구축

6 EDA : 상장폐지와 감사의견 데이터 분포

<상장폐지 및 감사의견 발생 비율>

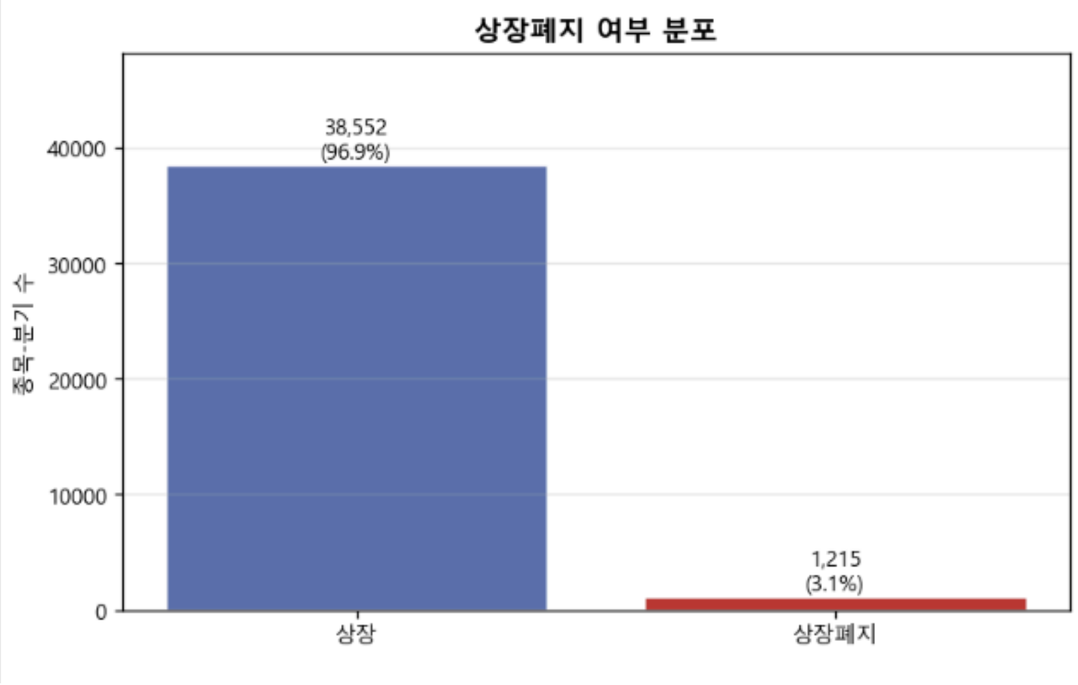

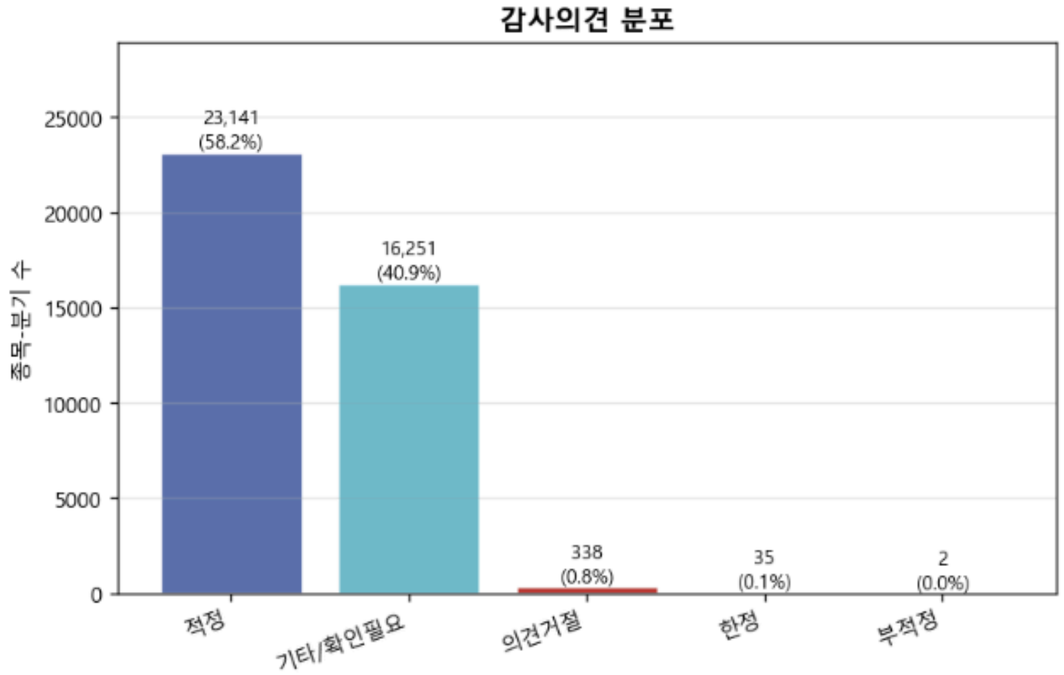

→ 오버샘플링 적용

6 EDA : 감사의견 → 2분기 후 상장폐지

<감사의견별 2분기 후 상장폐지 비율>

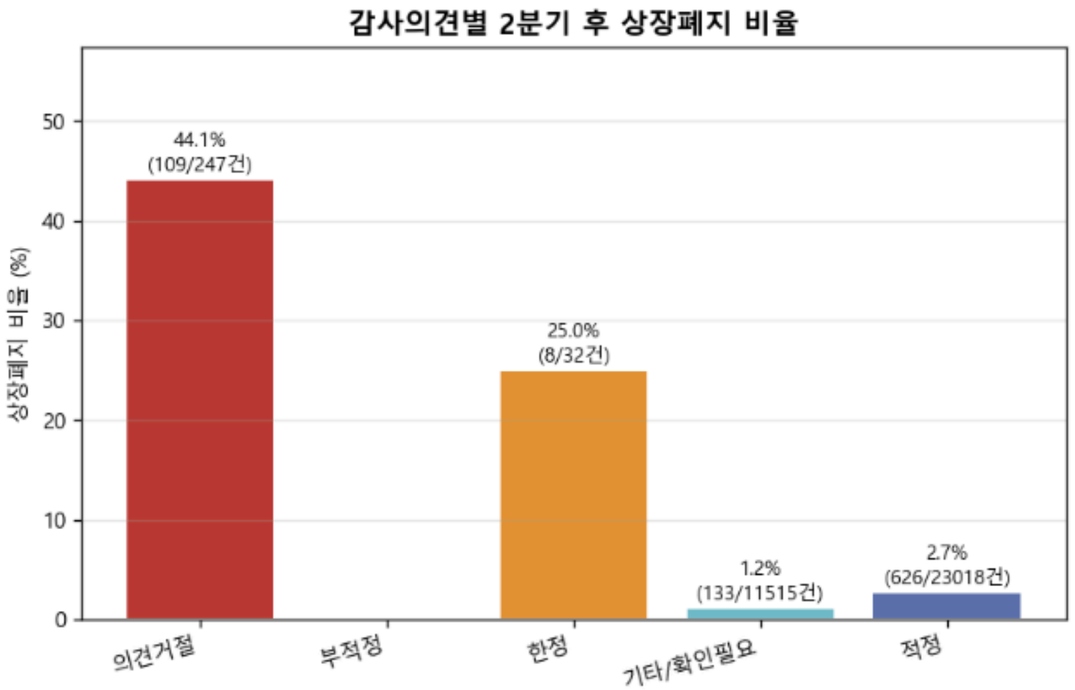

<동일 시점 기준 상장폐지 비율 비교>

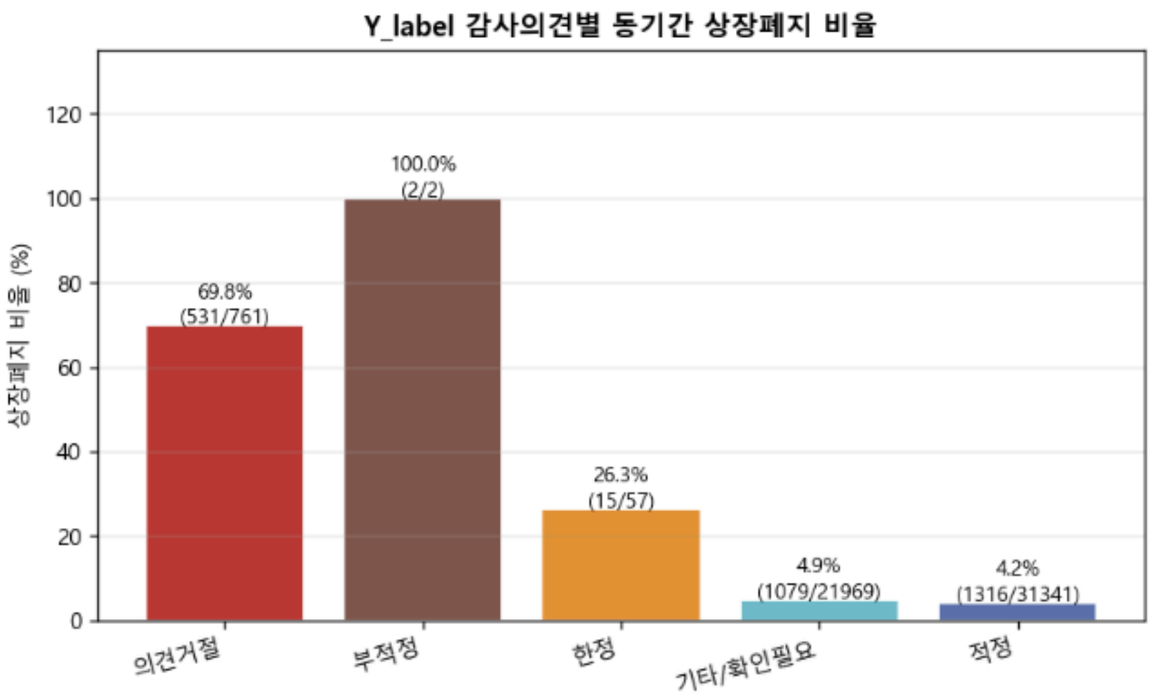

→ 감사의견은 상장폐지 이전에 나타나는 선행 신호

6 EDA : 불균형 해결 (확률 부스팅)

위험 감사의견은 상장폐지와 강하게 연결되지만 발생 빈도가 매우 낮음
→ 일반 분류 기준으로는 해당 신호를 놓칠 가능성이 존재

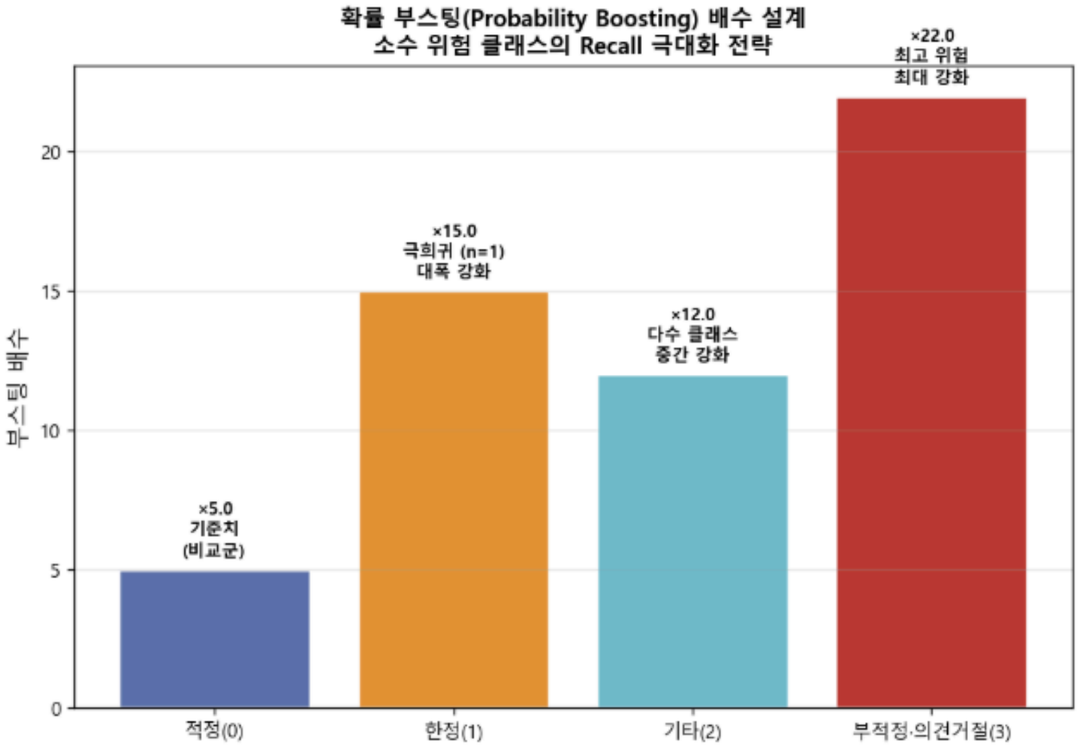

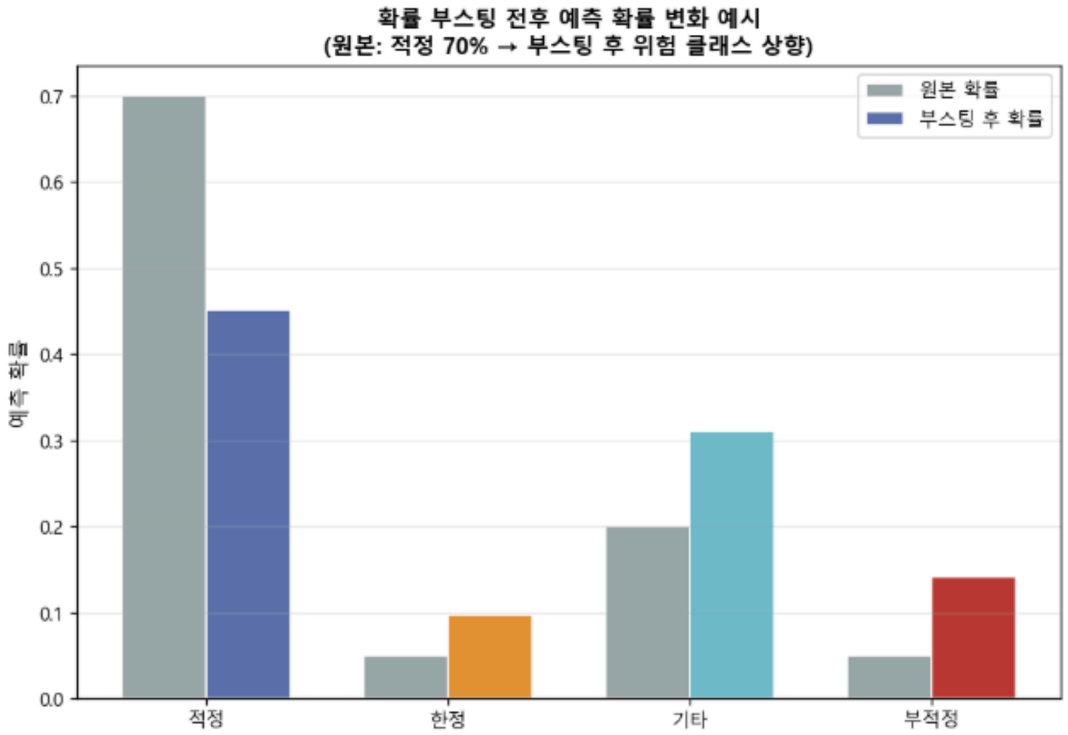

6 EDA : 불균형 해결 (확률 부스팅)

<피쳐 중요도>

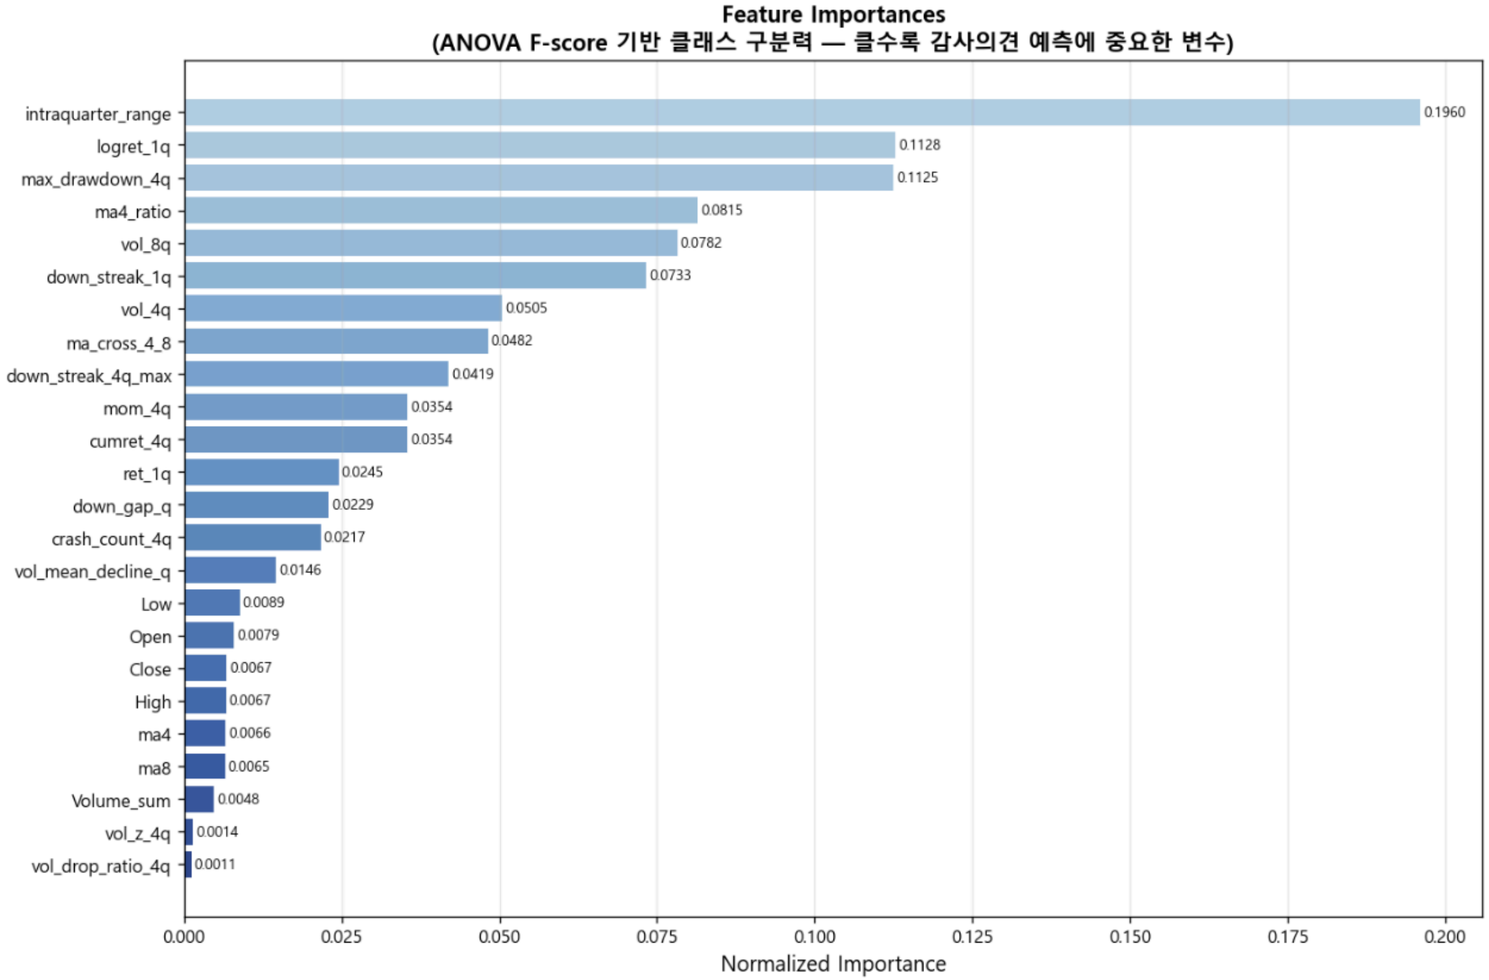

6 EDA : 모델 예측 성능

<감사의견 예측 모델 혼동행렬(2025Q1 ~ Q3)>

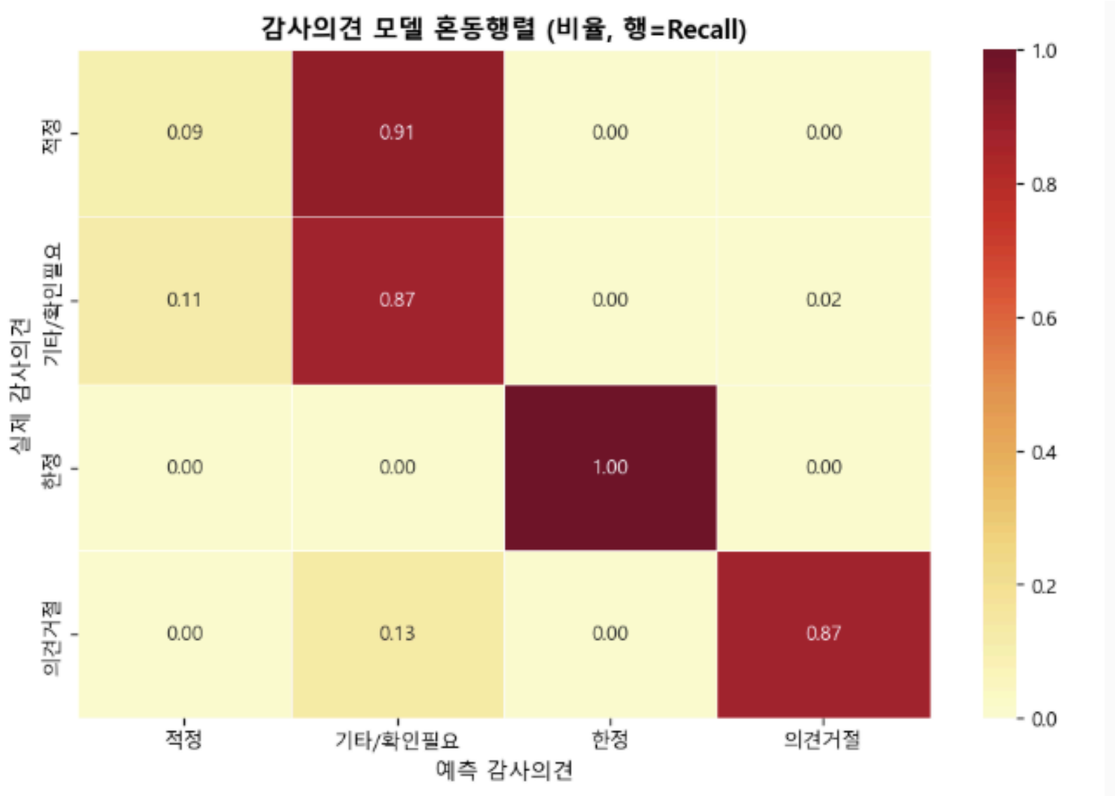

<감사의견 예측 모델 성능 분석
(test 데이터: 2025Q1 ~ Q3)>

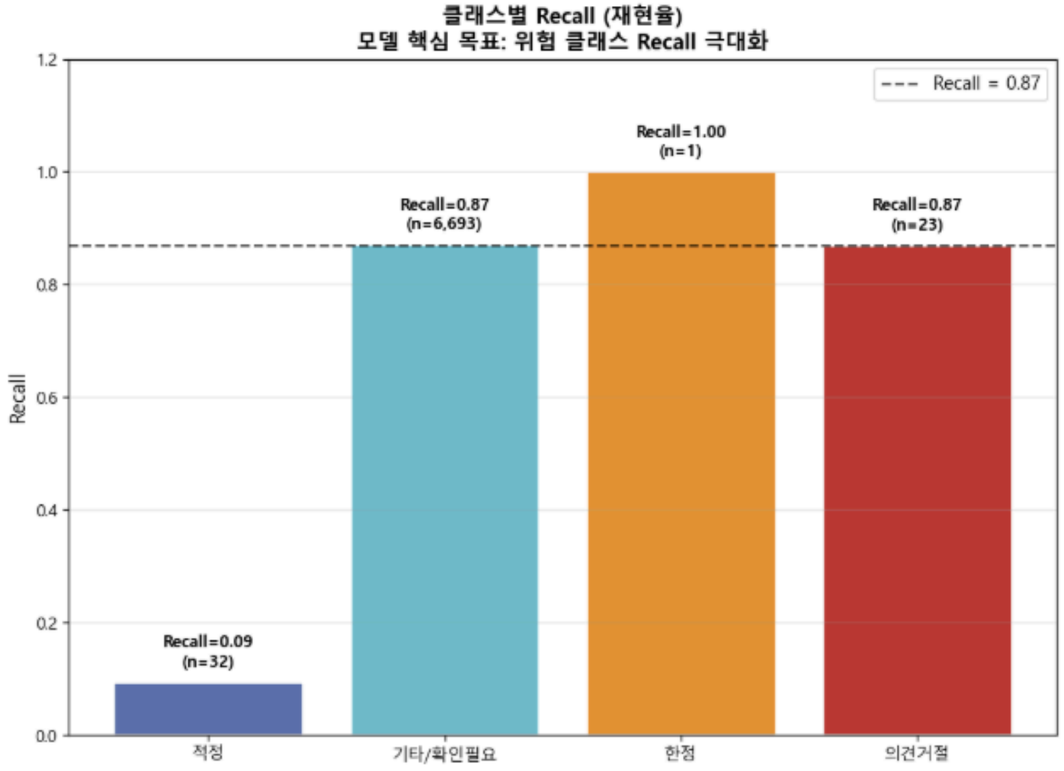

6 EDA : 감사의견 기반 위험 탐지

<2025 Q3 종목 리스크 등급 분포>

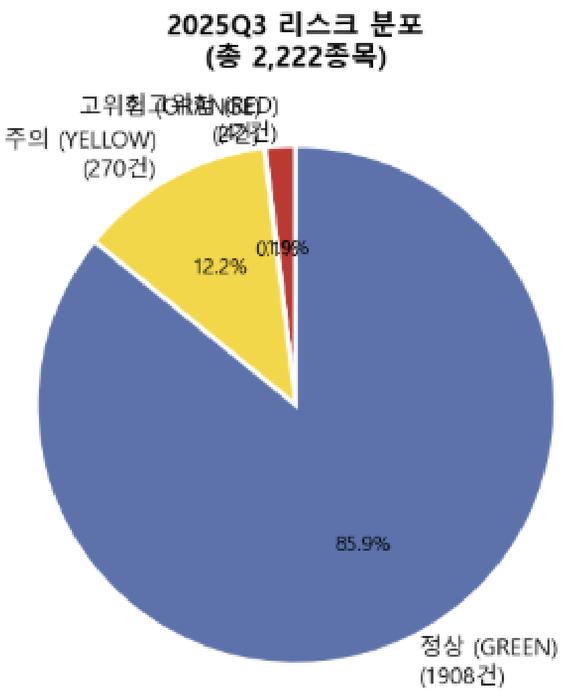

<2025 Q3 종목별 위험도 분포>

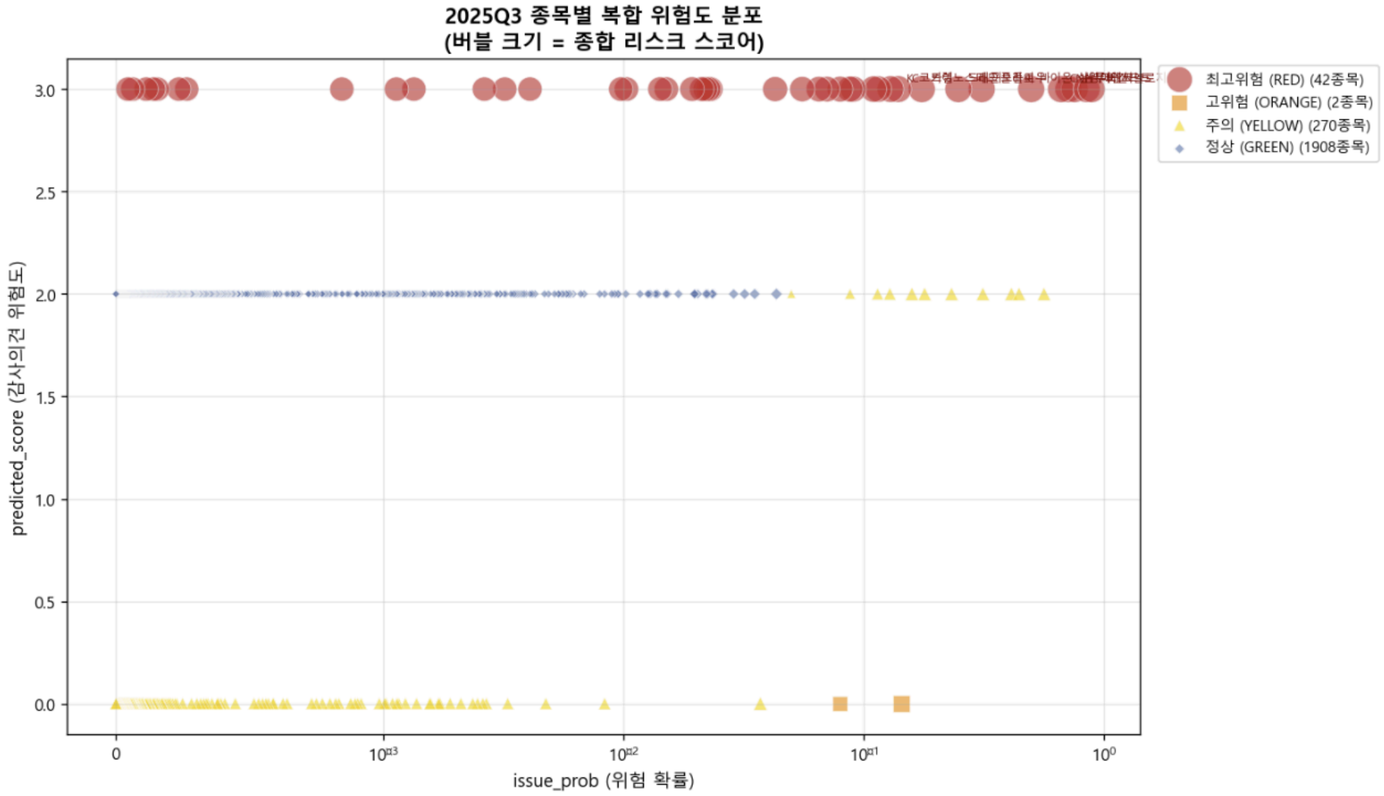

7 프로젝트 목표 - 재무데이터

재무제표의 후행성을 극복한 미래 리스크 예측

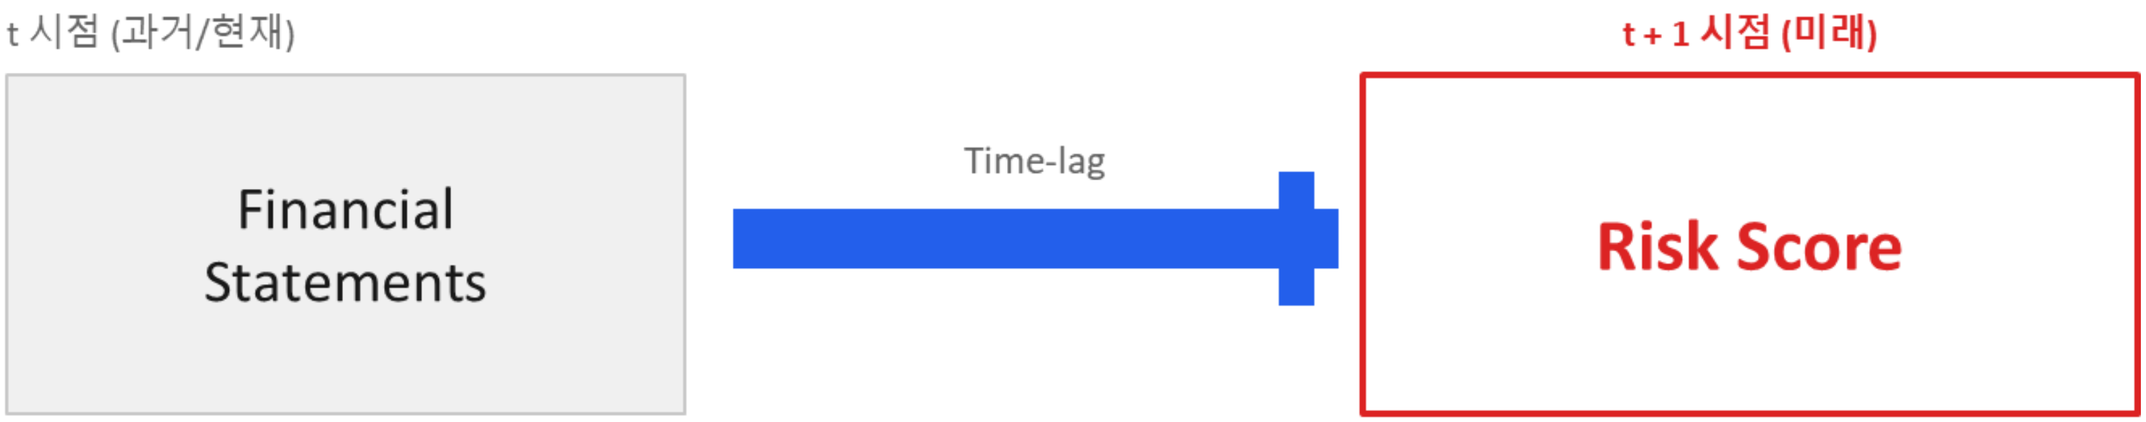

Goal

t + 1 시점 기업 리스크 스코어 예측

Target

KOSPI 및 KOSDAQ 전 상장사 (KRX)

7 데이터 수집

- **데이터 소스:** Open DART API

- **기간:** 2016 ~ 2025 (10년)

- **피쳐:** 재무상태표/손익계산서

- **Volume: 31개 피쳐**
- **Q1:** 21,432행 / **Q2:** 21,720행
- **Q3:** 22,024행 / **Q4:** 21,994행

```python
def get_integrated_data(corp_code, year):
    # 1. 연결재무제표(CFS) 우선 호출
    df = fetch('CFS')

    # 2. CFS 누락 시 별도재무제표(OFS) 대체
    if df is None:
        df = fetch('OFS')

    return df
```

7 데이터 전처리

1. 결측치 처리

- Column-wise: 결측률 > 20% 변수 제거
- Row-wise: 결측률 > 50% 기업 제거 (87,170 → 85,132)
- Interpolation: 직전 분기 값 보간 (Fillna) → 75,005행

2. 이상치 처리

- Method: Percentile Clipping (Winsorization)
- Range: 1% ~ 99% Quantile
- 대상: 성장률 변수 (sales_growth, asset_growth 등)

7 타겟 변수 구성

Score(t+1) = 100 − (P(audit) + P(delist) + P(admin))

- 상장폐지 위험 (Delisting Warning): -40 pts
→ 1,355건
- 관리종목 지정 (Admin Designated): -30 pts
→ 84건
- 감사의견 부적정 (Audit Penalty): Max -60 pts
→ 적정(0) / 한정(-30) / 부적정·의견거절(-60)

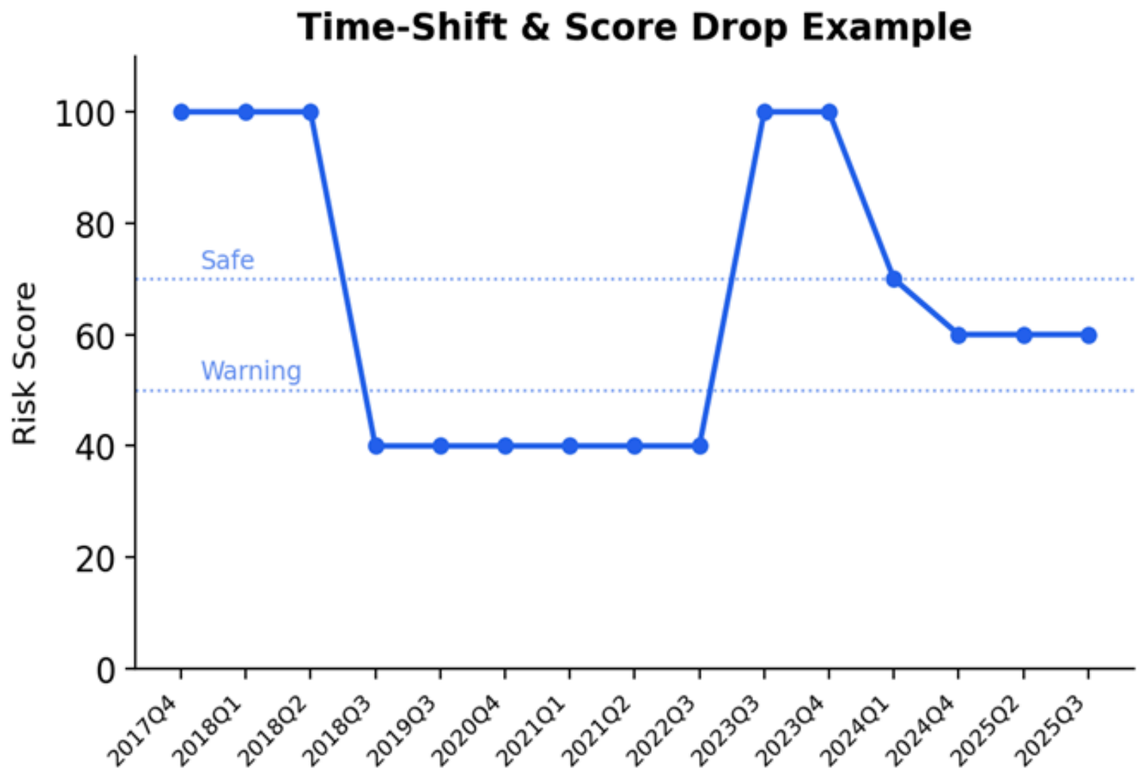

7 학습 설계

Time-Series Split

Train (~2021)	Valid (2022-23)	Test (2024)

Features

21개 – 재무제표 기반 지표
(Capital Ratio, Debt Ratio
Net Working Capital, etc.)

Train: 38,424행 (0.7%)
Valid: 17,031행 (0.8%)
Test: 9,073행 (2.4%)

Class Imbalance

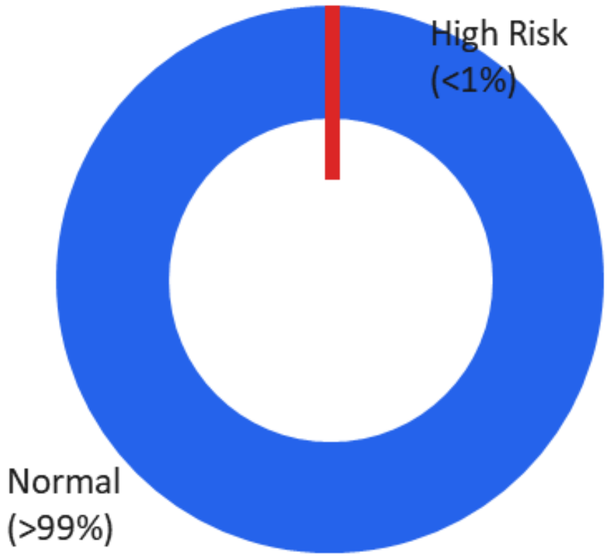

Score ≤ 70
Samples are extremely rare.

Evaluation Metrics

MAE: 전체 샘플의 평균 절대오차
RMSE: 오차를 제곱한 뒤 평균을 구하고, 그 값에 루트를 취한 지표
LOW MAE: score ≤ 70 기업 대상으로 계산한 MAE
Risk Accuracy (High Risk Only) : 실제 score ≤ 70 기업 중, 예측 오차가 ±10점 이내인 비율

7 모델링

전략	모델 / 방법	핵심 하이퍼파라미터
Tree Ensemble	ExtraTrees RandomForest XGBoost LightGBM	**ET/RF**: n_est=600, leaf=2, **XGB**: n_est=800, lr=0.03, depth=6, **LGB**: n_est=800, lr=0.03, leaves=31
Hyperparameter Tuning	ExtraTrees (Optuna 10 trials)	목적함수: MAE n_est, leaf, split, depth, features 탐색
가중치 전략	ExtraTrees× 5가지 가중치	linear: clip(100-y, 1) quadratic: $(100-y)^2/100$ log: log1p(100-y)+1 binary: y≤70→30, else→1 no_weight: None
EBM	Explainable Boosting Machine (Optuna 10 trials)	max_bins=192, interactions=19, lr=0.045, max_leaves=4, leaf=3

7 성능 비교

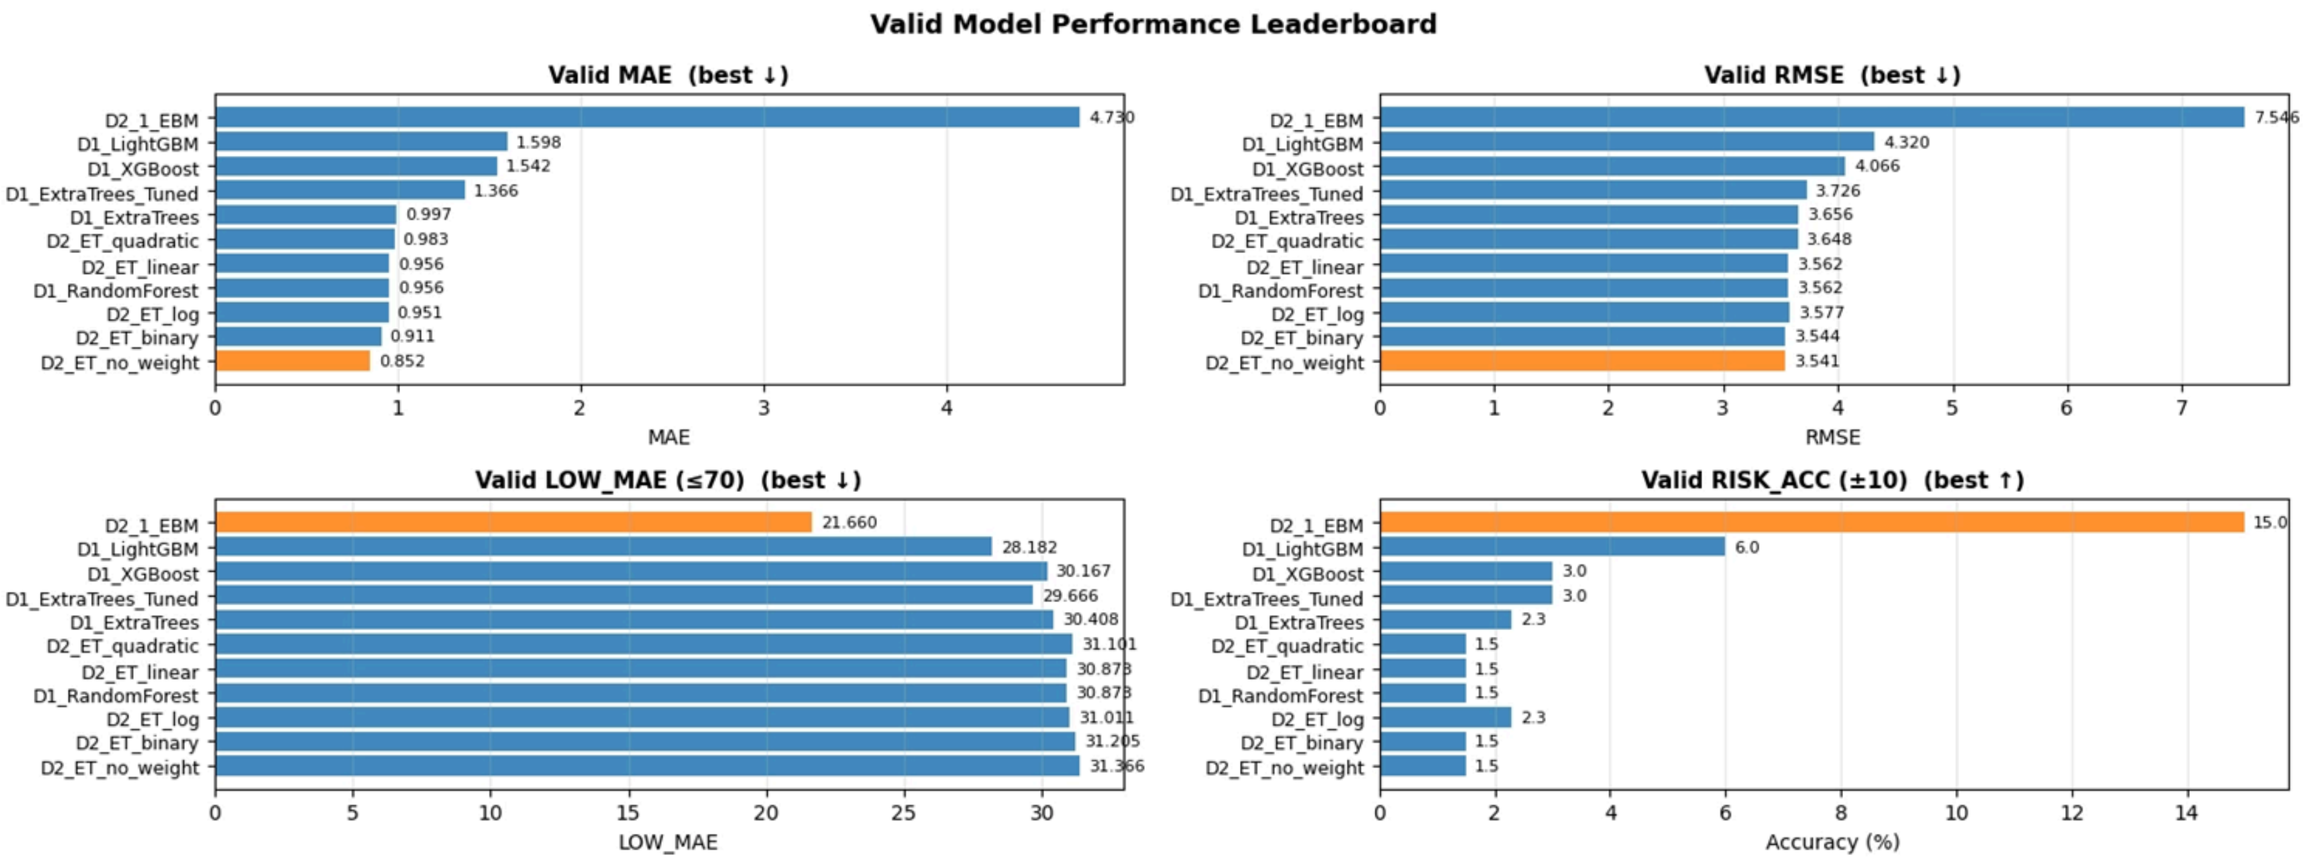

Trade-off Found: Elasticnet은 전체 오차가 가장 적으나(V_MAE 0.785), EBM이 고위험 기업 탐지(Risk Acc 15.0%, Test 22.5%)에는 유리함

샘플링 가중치 전략: 고위험 기업에 더 높은 가중치를 주는 전략을 모두 실험했으나, 가중치 없음(D2_ET_no_weight)이 Valid MAE 기준 가장 높았음. binary, log 가중치는로 오히려 전체 오차가 커졌음

7 Feature Importance

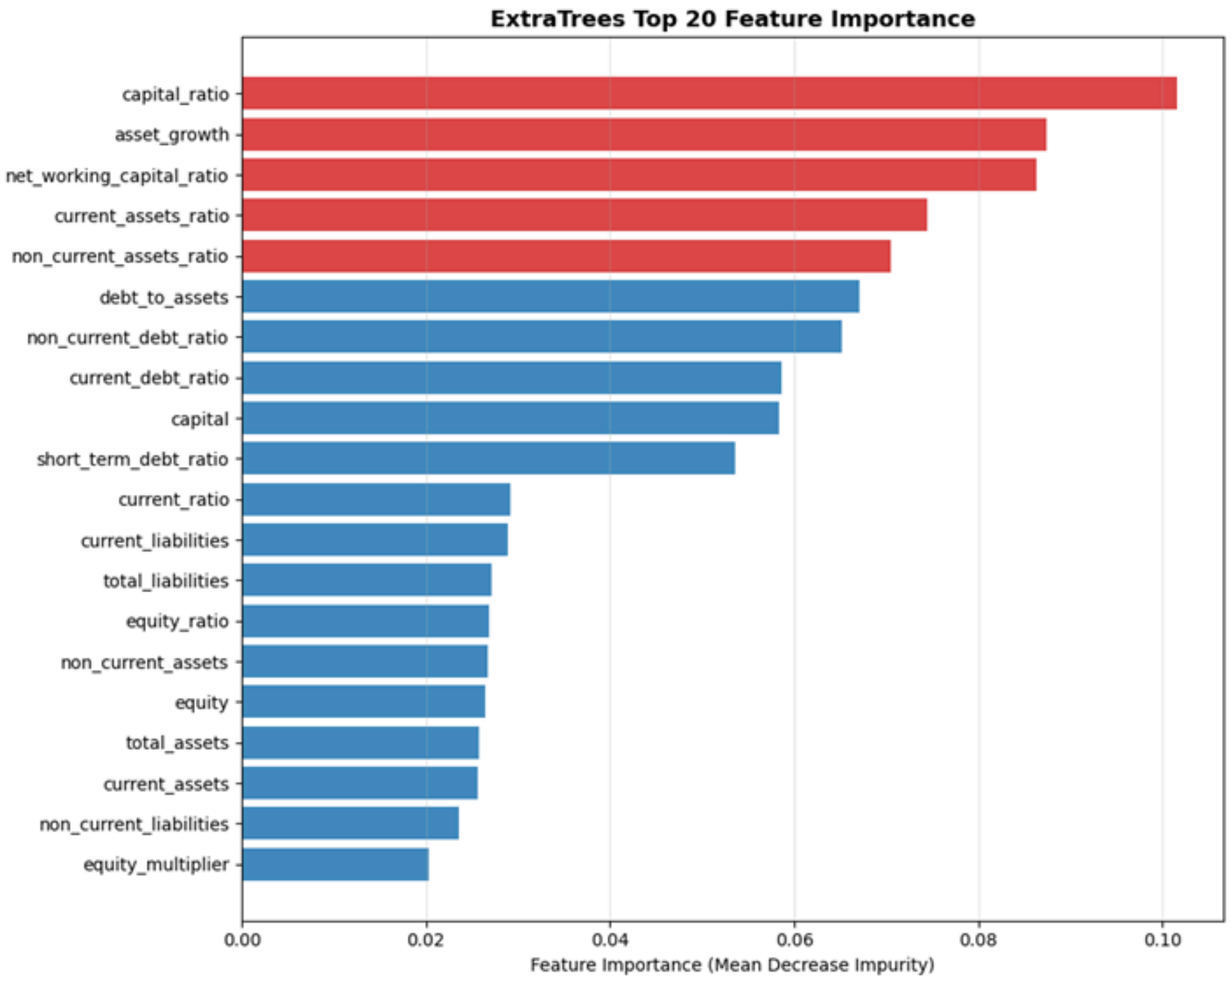

ExtraTrees 모델 구조 기여도 (Mean Decrease Impurity)

핵심 변수

capital_ratio(0.102)가 1위로 타 변수 대비 높음
→ 모델이 '자본의 질'을 가장 신뢰도 높은 근거로 활용

비율 지표 VS 절대액 지표

Top 10 중 절대액 지표는 capital 하나뿐
11~20위에 절대액 지표 집중 (0.020~0.028)
→ 기업 규모보다 재무 구조의 비율이 건전성을 더 잘 설명함

7 Permutation Importance

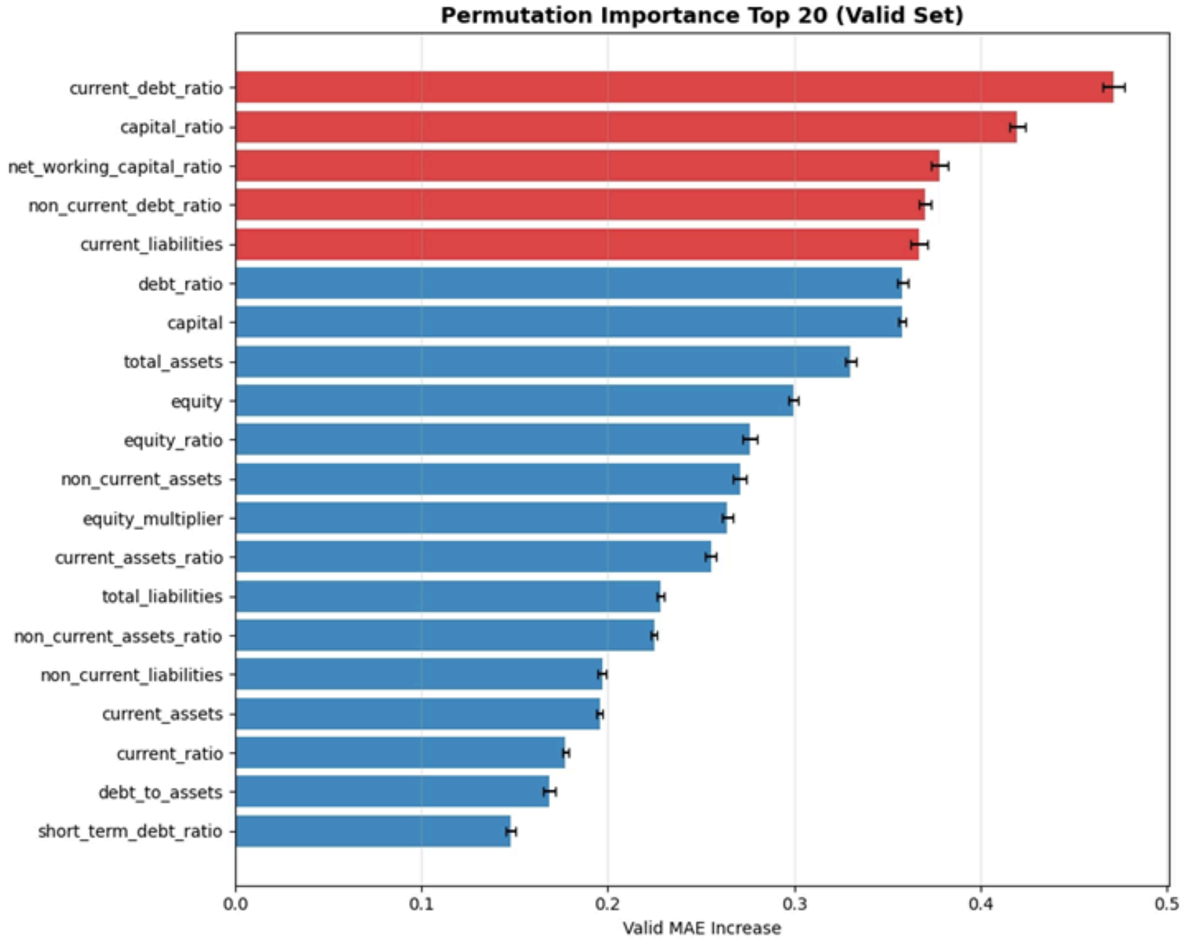

예측 파급력 1위: current_debt_ratio

current_debt_ratio ≈ 0.47로 - 1위
→ 단기 채무 상환 능력이 가장 결정적 예측 변수

FI vs PI 비교 인사이트

FI에서 낮았던 절대액 지표가 PI에서 급등:
current_liabilities(0.36, 5위), capital(0.35, 7위)
→ 트리 분기에는 덜 쓰이지만 실제 예측에는 큰 영향

예측 기여도: 해당 변수가 없으면 예측 오차(MAE)가 얼마나 커지는가

7 SHAP Value

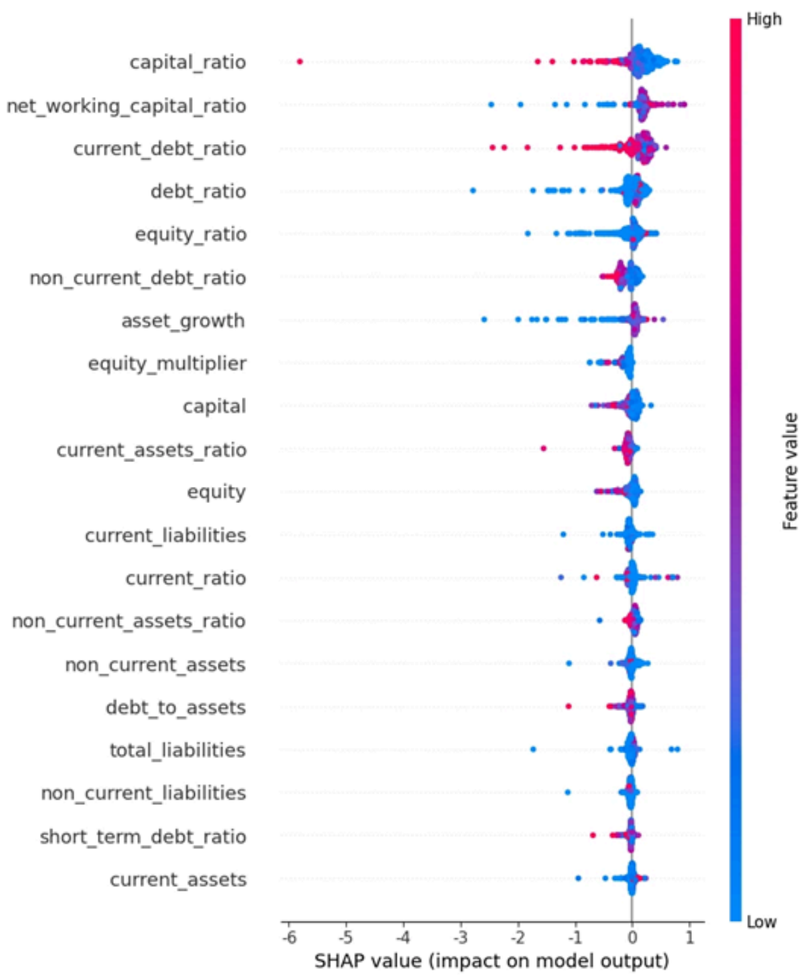

capital_ratio (자본비율)

비정상적으로 높거나 임계치를 벗어나면 점수를 대폭 삭감

net_working_capital_ratio (순운전자본비율)

높을수록 점수 상승
- 자금 여력이 풍부할수록 건전성 ↑

current_debt_ratio (유동부채비율)

높은 값이 왼쪽에 밀집 → 유동부채 증가 시 건전성 점수 하락

asset_growth (자산성장률)

낮은 값이 왼쪽에 퍼짐 → 성장 둔화/자산 감소를 부정적 신호로 인지

7 SHAP Value

Low Risk: Score 100(예측: 100)

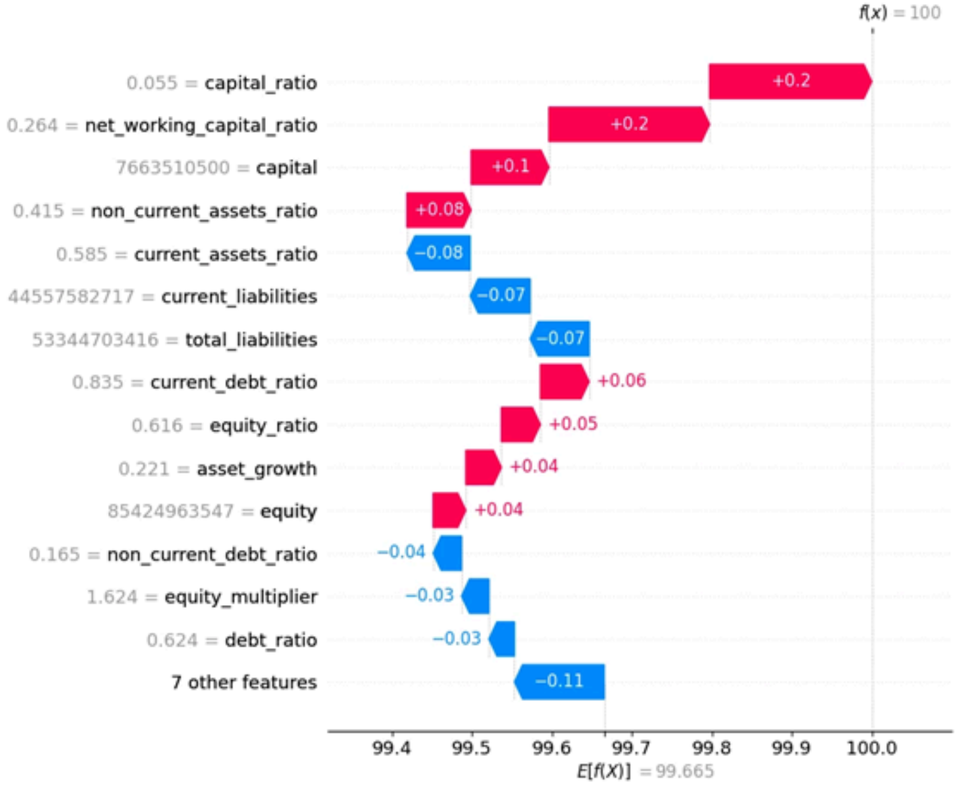

점수 상승 요인
capital_ratio(0.055) → +0.2
net_working_capital_ratio(0.264) → +0.2
점수 하락 요인: current_assets_ratio(-0.08), total_liabilities(-0.07)

High Risk: Score 20(예측:92.351)

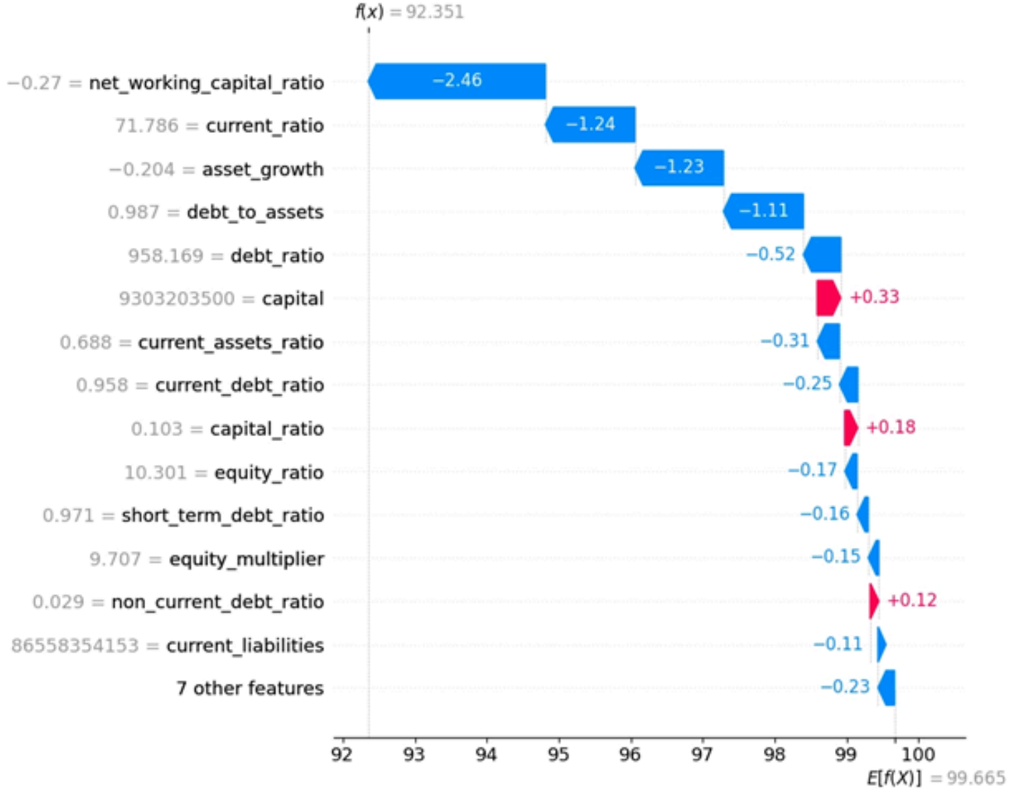

최대 감점: net_working_capital_ratio(-0.27) → -2.46
순운전자본 마이너스 = 단기 상환 능력 부족
current_ratio(-1.24), asset_growth(-1.23), debt_to_assets(-1.11)도 대폭 감점

감사합니다.

Q&A

B.D.A.I 9주 부트캠프: 심화반 FINDA 5팀