5 모델 구성 : 감사의견 예측

모델 선정 : RandomForest

1. 감사 데이터 불균형(Imbalance) 해결
2. 확률 기반의 커스텀 가중치 적용 가능

데이터 전처리 방법

1. Target들을 4개의 클래스로 정의.
2. 클래스별 가중치(boost_array)를 곱함.

모델 목표

감사의견 데이터 분석을 통해
기업의 '비적정' 감사의견을
미리 예측한다.

사용한 데이터

X 데이터 : 시장 데이터(주가)
Y 데이터 : 감사의견 데이터

모델 평가

1. 클래스들의 Recall(재현율)성능 극대화
2. 모델이 '비적정'이라고 맞추는 것에 집중

5 모델 설계 과정

① 데이터 업로드(Loading)

- train.csv(학습용)와 test.csv(검증용) 파일을 업로드.
- 기업들의 마켓 데이터, '감사의견'이 담긴 데이터프레임을 생성.

② 데이터 전처리 (Preprocessing)

- **라벨 인코딩(Label Encoding):** '상장폐지 여부'를 0과 1로 치환.
- **타겟 변수 설정:** 예측 목표인 '감사의견'을 4개의 클래스로 분류.
  - 0(적정), 1(한정), 2(기타), 3(부적정/의견거절)
- **데이터 정제:** 종목코드 같은 학습에 도움이 되지 않는 식별값 삭제.

③ 데이터 불균형 해소(Resampling)

- **오버샘플링:** 적은 클래스(1, 2, 3번 의견) 데이터를 인위적으로 복제.
- **데이터 증폭:** 가장 많은 '적정(0)' 데이터 양 기준, 나머지 1.2배로 증가.
  - 모델이 위험 신호에 민감하게 반응하도록 설계.

④ 모델 설계 및 학습 (Model Training)

- **앙상블 기법:** 의사결정 나무(n_estimators=200)가 데이터를 분석.
- **가중치 밸런스:** class_weight='balanced' 옵션을 적용.
  - 데이터 양이 적은 클래스에 더 높은 중요도를 부여.

⑤ 확률 기반의 결과 보정 (Recall Boosting)

모델이 예측한 결과값에서 위험 케이스에 가중치를 곱해 최종 판정 수행.

- **확률 추출:** 모델이 특정 기업을 보고 각 의견(0~3)일 확률을 계산.
- **배수 적용 (Boost Array):** 계산된 확률에 미리 정해둔 배수를 곱함.
  - 실제 확률이 낮더라도 강력한 경고를 보내도록 유도.
- **최종 결정:** 가중치가 곱해진 값 중 가장 높은 것을 최종 선택.
  - '위험을 놓치지 않는 것(Recall)'에 초점.

5 모델의 전처리 과정

범주형 변수의 수치화

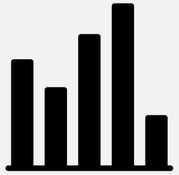

텍스트 데이터를 숫자로 변환

상장폐지 여부:
'상장'은 0, '상장폐지'는 1로 매핑하여 피처를 재생성한다.

타겟 변수 생성 및 라벨링 (Target Labeling)

'감사의견'을 4개 클래스로 재분류

4개의 클래스:
- 0 (적정): 감사의견이 정상적인 상태
- 1 (한정): 주의가 필요한 케이스
- 2 (기타/확인필요): 판단이 필요한 상태
- 3 (부적정/의견거절): 부정적 감사의견 상태

불필요한 피처 제거 (Feature Selection)

노이즈 혹은 예측에 관련이 없는 정보 삭제

삭제 대상:
주식 코드(stock_code), 기업명(Name), 분기 (quarter)와 같은 식별값들을 제외.
중복 및 정답지 제거:
'상장폐지 여부' 원본 텍스트 컬럼, 정답지인 '감사의견' 컬럼 삭제.

데이터 불균형 해소 (Resampling)

소수 데이터를 인위적으로 늘려 학습 능력을 강화

기준 설정:
가장 데이터가 많은 '적정'을 기준으로 설정.
소수 클래스 증폭:
'한정', '기타', '부적정' 데이터를 '적정' 데이터의 1.2배가 되도록 중복 추출(Resample).
소수 클래스를 다수 클래스보다 많이 하여, 모델이 위험 신호을 강하게 학습

5 모델 성능 평가

모델 성능

구분	Precision (정밀도)	Recall (재현율)	F1-Score
적정	0	0.09	0.01
한정	0.5	1	0.67
기타/의견필요	0.99	0.87	0.93
부적정 or 의견거절	0.17	0.87	0.28
Accuracy (정확도)			0.87

모델 성능 분석

1. 위험 포착 능력(Recall) 극대화:

- 모델 설계 의도대로 '부적정 혹은 의견거절' 클래스의 Recall이 0.87로 매우 높게 나타난다.
- 실제 부적정 기업 23건 중 20건을 맞추었다.

2. 데이터 불균형의 영향:

- '기타/의견필요' 데이터가 전체의 대부분(99%)을 차지하는 불균형한 구조이다.
- 모델의 가중치 조절을 통해 소수 클래스인 '한정'(1.00)과 '부적정'(0.87)의 검출력을 높였다.

3. 트레이드 오프(Trade - off):

- 재현율(Recall)을 강제로 높이다 보니, **'적정'**의견을 맞추는 정밀도(precision)에서 0에 가까운 수치가 나타나게 되었다.
- 이는 "안전한 기업을 위험하다고 오판을 해도, 위험한 기업을 제대로 판별하겠다는 의도를 반영하였다.

7 재무데이터 모델 비교 : 목표

재무제표의 후행성을 극복한 미래 리스크 예측

t 시점 (과거/현재)

Financial Statements

Time-lag

t + 1 시점 (미래)

Risk Score

Goal

t + 1 시점 기업 리스크 스코어 예측

Target

KOSPI 및 KOSDAQ 전 상장사 (KRX)

7 재무데이터 모델 비교 : 데이터 수집

- **데이터 소스:** Open DART API
- **기간:** 2016 ~ 2025 (10년)
- **피쳐:** 재무상태표/손익계산서
- **Volume: 31개 피쳐**
- **Q1:** 21,432행 / **Q2:** 21,720행
- **Q3:** 22,024행 / **Q4:** 21,994행

```python
def get_integrated_data(corp_code, year):
    # 1. 연결재무제표(CFS) 우선 호출
    df = fetch('CFS')

    # 2. CFS 누락 시 별도재무제표(OFS) 대체
    if df is None:
        df = fetch('OFS')

    return df
```