통계의 중요성

Mark Young

국대AI 업스테이지, ‘중국AI 도용 논란’ - 2026.01.02

이번 논란은 인공지능 스타트업 사이오닉에이아이(AI)의 고석현 대표가 문제를 제기하며 불거졌다. 고 대표는 지난 1일 페이스북과 링크드인에 “국민 세금이 투입된 프로젝트에서 중국 모델을 복사하여 미세 조정한 결과물로 추정되는 모델이 제출된 것은 유감”이라며 업스테이지의 솔라 오픈과 중국의 인공지능 스타트업 지푸에이아이에서 만든 지엘엠 4.5 에어(GLM-4.5-Air)의 유사도를 비교한 분석 글을 게시했다. 해당 글은 두 모델이 유사하다는 근거로 레이어정규화(LayerNorm) 파라미터(매개변수)의 코사인유사도(방향성의 유사도를 알 수 있음)를 비교하며 96.8% 동일하다는 내용이다.

업스테이지는 글로벌 인공지능 3강을 목표로 하는 정부가 국내 기업의 인공지능 개발을 지원하기 위해 지난해 6월 착수한 ‘독자 인공지능 파운데이션 모델 프로젝트’에 참여 중인 ‘국가대표 5개 정예팀’ 가운데 한 팀이다. 솔라 오픈은 이 사업의 일환으로 만들어진 인공지능 모델이다. 한국의 독자 인공지능 기술력 확보를 위해 국가에서 세금을 지원해 만들어졌다. 기술적 독립성을 확보한 모델이 아니고 ‘중국 모델의 복제본’이란 의혹이 사실로 드러나면, 개발사인 업스테이지는 물론 지난 6월부터 평가를 이어오며 이 기업을 최종 5개 정예팀 가운데 하나로 선정한 정부 사업 자체의 신뢰도에도 타격이 불가피하다. 이에 김성훈 업스테이지 대표는 해당 글에 곧바로 댓글을 달고 공개 검증을 제안했다.

레이어의 연결고리를 뜻하는 레이어놈(LayerNorm)이 GLM-4.5-에어의 레이어가 유사하다는 주장에 대해 김 대표는 "솔라, GLM, 파이(Pi)의 유사도를 측정했을 때도 높은 값이 나온다"라며 "(사이오닉 AI가 제시한 지표가 아닌) 다른 지표로 보면 솔라와 GLM-4.5-에어는 유사성이 낮다"라고 반박했다.
또 모델 구조가 유사하다는 주장에 대해서는 "대형언어모델(LLM) 서빙 툴과 생태계 호환성을 확보하려면 구조가 어느 정도 비슷해질 수밖에 없다"라며 "사용성과 호환성을 고려한 설계와 LLM 오픈소스 생태계 교류의 결과다"라고 설명했다.
그러면서 "솔라는 **덴스 레이어**가 없고 GLM은 **덴스 레이어**가 있어 모델 구조가 다르다"라고 부연했다.

지표의 함정: "왜 다른 지표로 보면 유사도가 낮아지는가?"

사이오닉 AI가 제시한 지표(아마도 Raw Cosine 기반일 가능성이 높음)에서 유사도가 높게 나온 이유는 LLM 임베딩의 **비등방성 (Anisotropy)** 때문일 확률이 큽니다.

- **Raw Cosine의 한계:** 현대의 트랜스포머 모델들은 학습 과정에서 레이어 가중치나 임베딩이 특정 방향으로 쏠리는 경향이 있습니다. 이 경우, 전혀 다른 두 모델을 비교해도 원점을 기준으로 한 각도(Raw Cosine)를 재면 0.9 이상의 높은 수치가 나옵니다.

- **Centered Cosine/Pearson의 효과:** 김 대표가 말한 '다른 지표'가 바로 이것입니다. 각 모델 가중치의 평균값을 빼고 '변화의 패턴'만 비교하면, 겉보기에 비슷해 보이던 수치가 급격히 떨어지며 **두 모델이 독립적으로 학습되었음**이 드러나게 됩니다.

GLM-4.5 (335B)

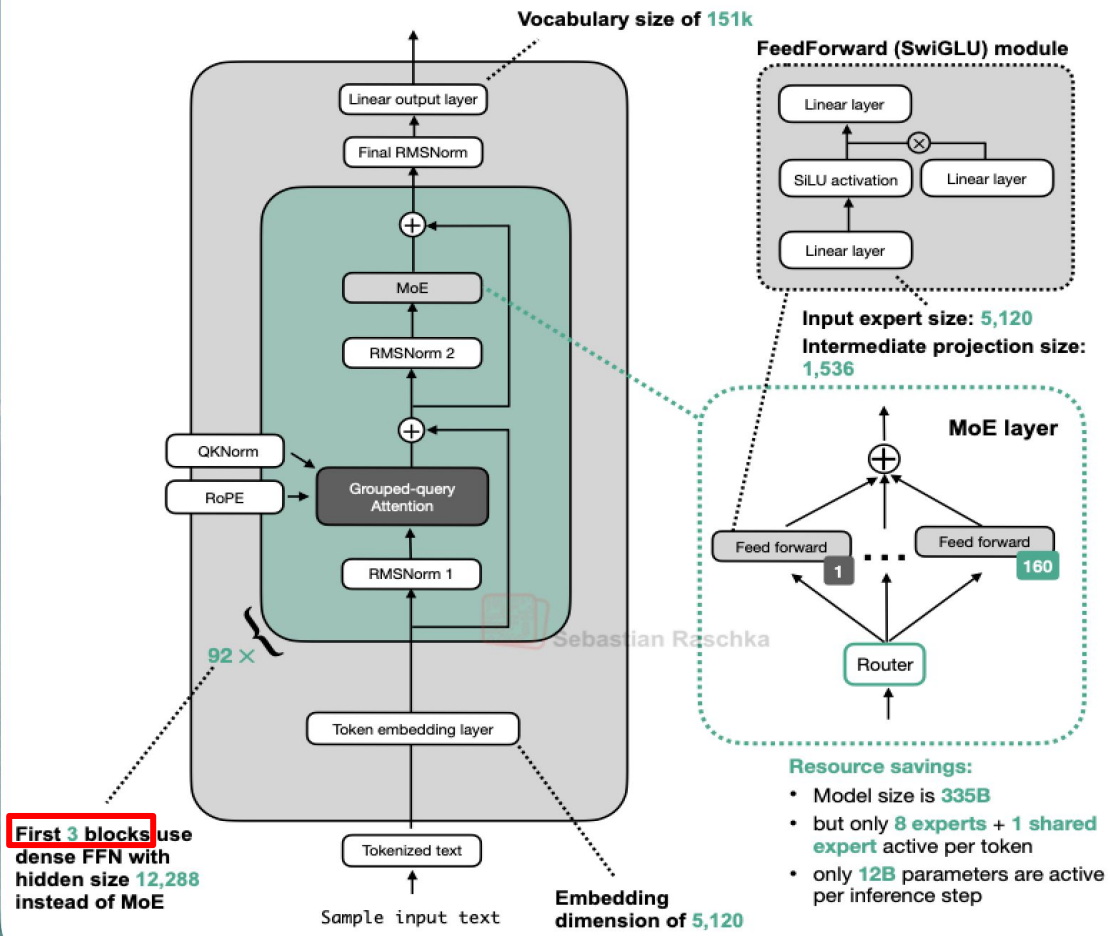

GLM-4.5의 Dense Layer 위치

이미지의 왼쪽 하단에 있는 **검은색 점선 화살표와 텍스트**를 주목해 주십시오.

- **위치:** 모델의 가장 앞부분인 첫 3개의 블록(First 3 blocks)
- **특징:** 이 구간은 MoE(전문가 선택형) 방식이 아니라, **Dense FFN(밀집 피드포워드 네트워크)** 방식을 사용합니다.
- **상세 스펙:** 이 Dense Layer들의 Hidden Size(은닉층 크기)는 **12,288**로 설계되어 있습니다.

2. 왜 여기에 Dense Layer를 두었을까?

- **GLM-4.5:** 초반 레이어에 Dense 구조를 배치하여 입력된 토큰의 기초적인 특징을 모든 파라미터가 골고루 학습하도록 설계했습니다.

LLM의 임베딩 공간(Embedding Space)에서 두 벡터가 얼마나 닮았는지를 측정할 때, 우리는 흔히 이 지표들을 사용합니다.
결론부터 말씀드리면, 이 세 지표는 '데이터를 어떻게 전처리(원점 이동)하고 비교하느냐'의 차이일 뿐 수학적으로는 매우 긴밀하게 연결되어 있습니다.

1. 세 지표의 정의와 관계식

각 지표를 수식과 함께 이해하면 그 차이가 극명하게 보입니다.

① Raw Cosine Similarity (원시 코사인 유사도)

일반적으로 우리가 '코사인 유사도'라고 부르는 것입니다. 두 벡터 사이의 각도를 측정하며, 데이터의 평균을 고려하지 않고 원점을 기준으로 계산합니다.

② Centered Cosine Similarity (중심화 코사인 유사도)

각 벡터에서 해당 벡터의 평균값을 뺀 후 코사인 유사도를 구하는 방식입니다. 데이터의 '절대적 위치'보다는 '변화의 패턴'에 집중합니다.

③ Pearson Correlation Coefficient (피어슨 상관계수)

통계학에서 두 변수 간의 선형적 상관관계를 나타내는 지표입니다.

> **중요 포인트:** 수학적으로 **Centered Cosine은 Pearson Correlation과 동일**합니다.

왜 LLM에서 이 차이가 중요한가요?

LLM 임베딩은 종종 특정 방향으로 치우쳐 있는 **'Anisotropy(비등방성)'** 문제를 겪습니다. 모든 벡터가 특정 좁은 원뿔(Cone) 안에 모여 있으면, Raw Cosine 값은 전부 0.9 이상으로 높게 나와 변별력이 떨어집니다. 이때 Centered Cosine(Pearson)을 사용하면 공통된 평균 성분을 제거하여, 두 텍스트 간의 순수한 '상대적 차이'를 더 잘 잡아낼 수 있습니다.

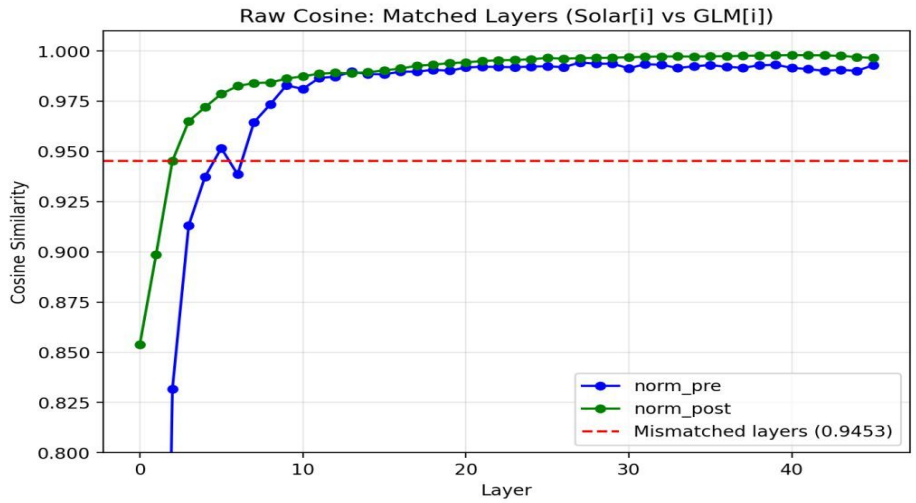

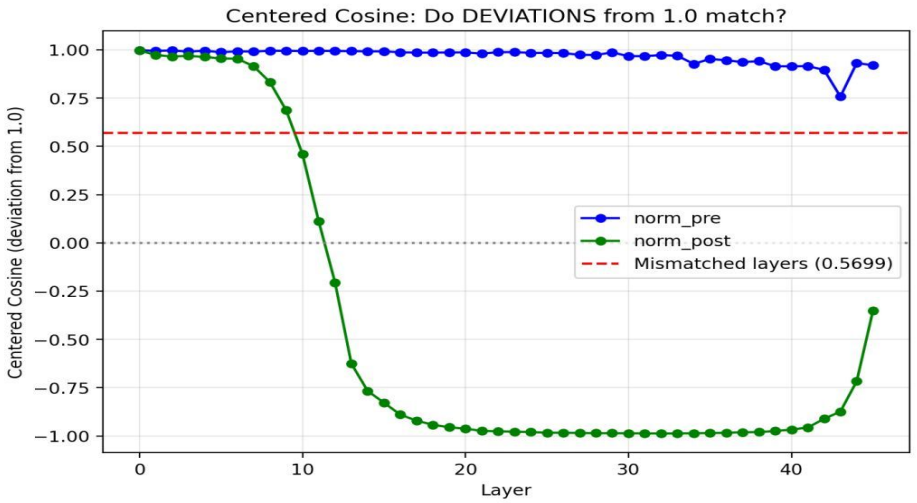

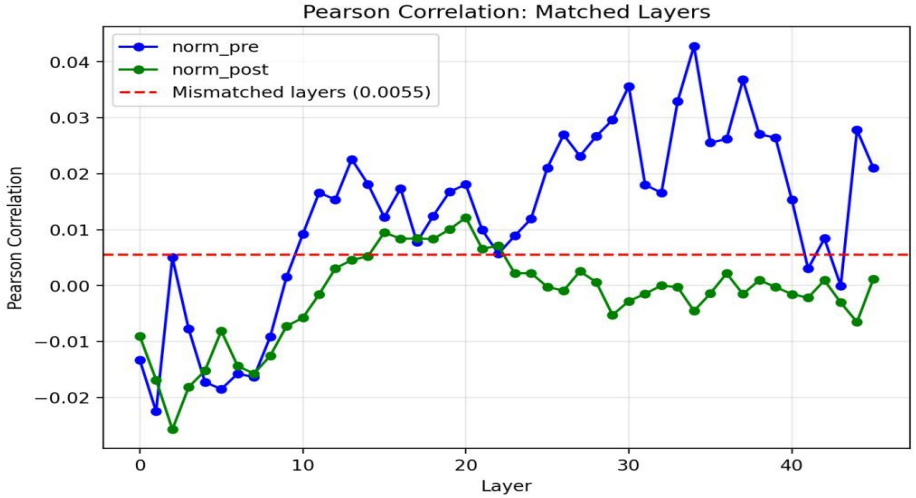


```
PROVENANCE EVIDENCE SUMMARY
===========================

1. RAW COSINE SIMILARITY (LayerNorm weights)
   Matched layers (Solar[i] vs GLM[i]):  0.9676
   Mismatched layers (control):          0.9453

   -> Both high because LayerNorms ≈ 1.0 (uninformative)

2. CENTERED COSINE (deviation patterns)
   Matched layers:    0.2583
   Mismatched layers: 0.5699

   -> THIS IS THE KEY METRIC!
   -> If centered cosine >> 0, the DEVIATION PATTERNS match
   -> Random/unrelated models: centered cosine ≈ 0

3. PEARSON CORRELATION
   Matched layers:    0.0054
   Mismatched layers: 0.0055

4. TOKENIZER ANALYSIS
   Solar = GLM + 45,279 new tokens
   53.1% of GLM tokens found in Solar
   24.1% of GLM BPE merges preserved

5. CONCLUSION
   [MODERATE EVIDENCE] Possible shared lineage
   - Some deviation pattern matching detected
```

컴퓨터 공학에서 'From Scratch'는 '아무것도 없는 상태에서 시작한다'는 뜻입니다. LLM 개발에서 이 용어는 이미 학습된 기존 모델(Llama, Mistral 등)의 가중치(Weights)를 가져다 쓰지 않고, **무작위로 초기화된 (Randomly Initialized) 상태에서 거대 데이터를 부어 처음부터 끝까지 직접 학습**시키는 방식을 의미합니다.

1. From Scratch 개발의 핵심 단계

이 방식은 단순히 코딩을 잘하는 것을 넘어, 막대한 자본과 고도의 공학적 설계가 결합된 과정입니다.

- **데이터 구축 (Data Curation):** 인터넷 상의 텍스트, 코드, 논문 등 수조 개의 토큰(Trillions of Tokens)을 직접 수집하고 정제합니다.
- **아키텍처 설계 (Architecture Design):** 첨부된 이미지 속 GLM-4.5의 사례처럼, 레이어 수, 임베딩 차원, Dense와 MoE의 혼합 비율 등을 직접 결정합니다.
- **사전 학습 (Pre-training):** 수천 장의 GPU(H100 등)를 몇 달간 가동하여 모델이 언어의 구조와 지식을 스스로 깨우치게 만듭니다.
- **토크나이저 개발 (Tokenizer):** 모델이 텍스트를 읽는 단위인 토크나이저(예: GLM의 151k Vocab)를 데이터 특성에 맞춰 직접 설계합니다.

2. 왜 'From Scratch'가 대단하다고 평가받는가?

업계에서 이 방식을 성공시킨 기업을 '기술적 독립'을 이룬 것으로 간주하는 이유는 다음과 같습니다.

① 기술적 난이도 (Stability)

수천 대의 GPU가 병렬로 연결되어 수개월간 연산을 수행할 때, 수치가 폭발(Loss Explosion)하거나 학습이 멈추는 현상이 빈번합니다. 이를 해결하는 '학습 안정화 기술'은 기업의 극비 자산입니다.

② 막대한 비용 (Cost)

한 번의 풀 트레이닝(Full Training)에 수십억에서 수백억 원의 전기료와 인프라 비용이 발생합니다. 실패 시 리스크가 매우 큽니다.

③ 라이선스에서의 자유

기존 모델을 튜닝(Fine-tuning)한 모델은 원본 모델의 라이선스 제약(예: 상업적 이용 제한 등)을 따르지만, From Scratch 모델은 개발사가 모든 권리를 가집니다.

1. 지표의 통계적 착시: "코사인 유사도의 함정"
의혹을 제기한 측은 레이어놈(LayerNorm)의 유사도가 0.989로 매우 높다는 점을 근거로 들었습니다. 이에 대해 김 대표는 다음과 같이 반박합니다.

- **지표 선택의 오류:** 레이어놈은 모델 전체 파라미터의 극소수(약 0.0004%)이며, 구조적 특성상 어떤 독립 모델끼리 비교해도 **Raw Cosine**으로는 높게 측정되는 경향이 있습니다.
- **패턴의 상이함:** 데이터를 정규화한 피어슨 상관계수(Pearson Correlation)나 **Centered Cosine**으로 분석하면, 솔라와 GLM 간의 유사성은 급격히 낮아지며 두 모델이 서로 다른 학습 경로를 거쳤음을 증명합니다.

2. 생태계 표준화: "자동차 바퀴가 둥근 이유"
모델 구조가 비슷하다는 주장에 대해서는 '호환성'과 '최적화'라는 실무적 이유를 제시합니다.

- **서빙 효율성:** vLLM이나 TensorRT-LLM 같은 글로벌 표준 추론 엔진에서 잘 돌아가려면, 업계에서 검증된 표준 아키텍처(RMSNorm, RoPE 등)를 따르는 것이 합리적인 설계 선택입니다.
- **오픈소스 교류:** 최신 LLM들은 서로의 장점을 흡수하며 진화하므로, 외형적 구조가 유사해지는 것은 베낀 것이 아니라 **기술적 수렴**으로 보아야 한다는 논리입니다.

3. 아키텍처의 근본적 차이: "Dense vs MoE"
가장 결정적인 차이로 **밀집 레이어(Dense Layer)의 유무**를 꼽았습니다.

- **구조적 차별화:** GLM은 초반 레이어에 모든 파라미터가 참여하는 **Dense FFN**을 배치한 하이브리드 구조인 반면, 솔라는 이와 다른 구조를 채택하고 있습니다. 이는 엔진의 핵심 설계도가 다르다는 것을 의미하며, 단순히 가중치를 복사해서는 구현할 수 없는 차이입니다.

4. 개발 방식의 진정성: "From Scratch의 증거"
김 대표는 솔라가 무작위 상태에서 학습을 시작했다는 '프롬 스크래치(From Scratch)'임을 강조하며 데이터 증거를 제시했습니다.

- **학습 로그(WandB):** 학습 초기에 손실값(Loss)이 급증했다가 서서히 떨어지는 과정과 지능(MMLU 성능)이 0.25에서 0.77까지 점진적으로 상승하는 '성장 기록'을 공개했습니다. 이는 이미 완성된 모델을 튜닝(Fine-tuning)했을 때는 절대 나타날 수 없는 패턴입니다.

LLM 서비스 설계 전문가로서, 머신러닝 성과 지표(Metric) 분석을 통해 서비스를 고도화하는 실무적인 방안 제안

단순히 '정확도가 높다'는 지표에 매몰되는 것이 아니라, **서비스 단계별 핵심 지표를 설정하고 이를 모델 개선의 피드백 루프로 연결**하는 것이 고도화의 핵심입니다.

1. 지표 체계의 다각화 (Multi-faceted Metrics)

서비스 고도화의 시작은 '무엇을 측정할 것인가'를 정의하는 것입니다.

구분	핵심 지표 (Metrics)	서비스 고도화 기여 포인트
품질 지표	GPT-4o-as-a-Judge, RAGAs (신뢰성/관련성/정답률)	환각(Hallucination) 현상을 수치화하여 답변의 신뢰도 보장
운영 지표	TTFT(첫 토큰 생성 시간), TPS(초당 토큰 수), P99 Latency	사용자 경험(UX) 개선을 위한 인프라 및 모델 경량화 시점 결정
비즈니스 지표	과업 성공률(Task Success), CSAT(고객만족도), 전환율	모델의 성능 향상이 실제 매출이나 비용 절감으로 이어지는지 증명

지표 기반의 고도화 3단계 전략

① 데이터 편향성 및 '골든 데이터셋' 구축

지표 분석의 신뢰도를 높이기 위해, 서비스의 목적을 가장 잘 반영하는 200~500개의 'Golden Dataset'을 구축합니다.

- **분석:** Raw Cosine 유사도로는 발견하기 어려운 모델 간의 미세한 성능 차이를 **Pearson Correlation**이나 **Centered Cosine**으로 분석하여 모델의 고유한 답변 경향성을 파악합니다.
- **고도화:** 특정 유형의 질문에서만 성능이 떨어진다면, 해당 데이터만 선별하여 미세 조정(Fine-tuning)을 수행합니다.

② RAG 파이프라인의 수치적 최적화

대부분의 LLM 서비스는 검색 증강 생성(RAG)을 사용합니다. 이때 단순히 "답변이 틀렸다"가 아니라 어디가 문제인지 지표로 쪼개야 합니다.

- **Faithfulness(충실도):** 답변이 검색된 문서에 근거하는가?
- **Answer Relevance(답변 관련성):** 답변이 질문의 의도에 부합하는가?
- **Context Precision(문맥 정밀도):** 검색된 문서들이 정말 질문과 관련이 있는가?
- **고도화:** 이 지표들을 분석하여 **임베딩 모델을 교체**하거나, **벡터 DB의 검색 알고리즘**을 튜닝합니다.

③ 옵저버빌리티(Observability) 기반 실시간 개선

출시 후 사용자 데이터를 실시간으로 모니터링하여 지속적으로 업그레이드합니다.

- **방법:** Langfuse나 Datadog LLM Observability 같은 도구를 사용하여 **응답 시간과 토큰 소모량**을 추적합니다.
- **고도화:** 특정 구간에서 Latency가 급증한다면 양자화(Quantization)를 적용하거나, **MoE 라우팅 로직**을 수정하여 효율을 높입니다.

통계란 무엇인가?

◆ 통계학의 활용

경영학, 경제학, 심리학, 사회학, 교육학, 신문 방송학, 물리학, 의학 산업공학,

기계금속 등 모든 학문에 활용됨

◆ 패턴인식

불확실성극복 →지식의 창출과 발견

로버트 루트번스타인과 미셸 루트번스타인은 '생각의 탄생' **(Sparks of Genius)**에서 "모든 지식은 관찰에서부터 시작된다." **("All knowledge begins in observation.")**

관찰을 통해 특별한 형태, 즉 패턴을 인식하고, 적절한 가정 하에 이론을 정립한 후 입증과정을 거치는 것.

통계학의 정의 및 구성

통계학	자료를 의사결정에 도움이 되는 의미있는 정보로 전환하는 방법에 관하여 연구하는 학문

모집단

표본

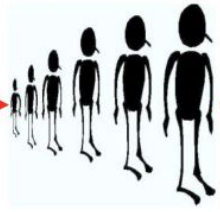

자료

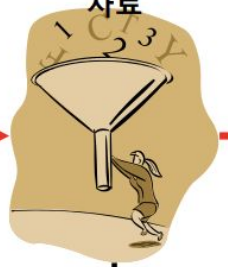

기술통계

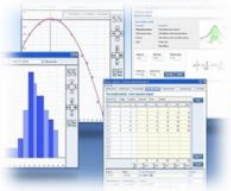

정보

사람, 물건, 조건, 상황을 묘사하는 것으로
기본적인 사실들의 집합

의사결정에 도움이 되도록 가공되거나
요약된 형태의 자료

추론통계

현대 통계학은 표본 자료에 의거 그 표본이 추출된 모집단에 대한 통계적 추론과 분석실시

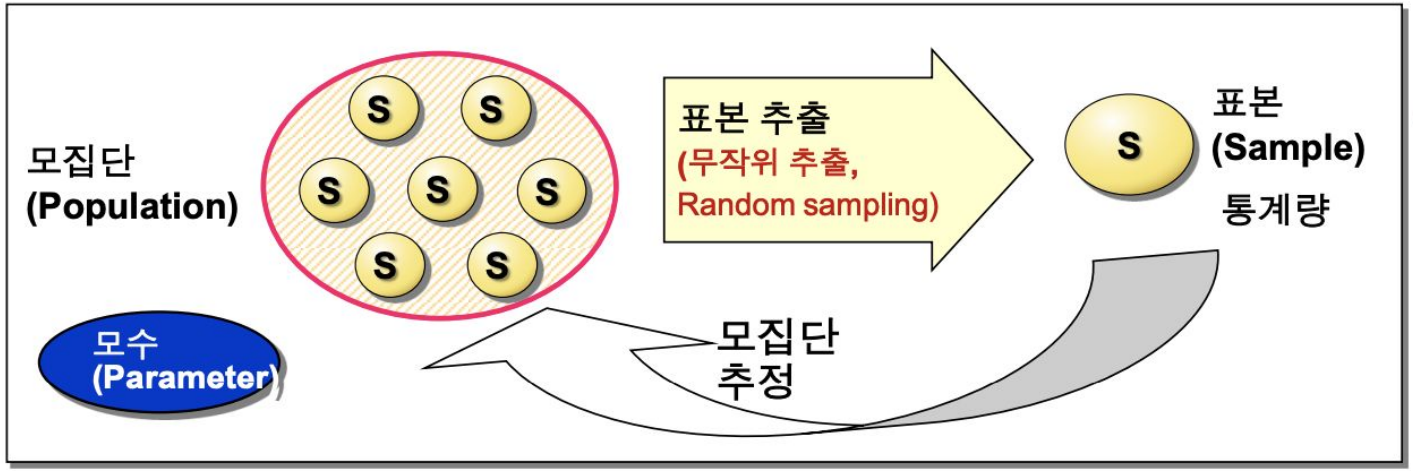

- **모집단(母集團: Population)** : 얻고자 하는 정보와 관련있는 모든 개체 즉,관심의 대상이 되는 전체 집단을 의미한다.(연구대상이 되는 물체나 사람들의 총체(總體))
- **표본(標本: Samples)** : 모집단의 일부분으로, 원하는 정보를 얻기 위해 수행한 관측 과정을 통하여 실제로 얻어진 측정결과의 집합이다.(조사 대상으로 채택된 일부 집단)
- **모수(母數)** : 모집단의 特性을 수치(data)로 나타낸 것
- **통계량(統計量)** : 표본의 특성을 수치로 나타낸 것

통 계

기술통계

자료를 적절하게 그림, 도표 또는 수치로 특성을 요약하고 기술하는 통계

추론통계

모집단으로부터 추출한 표본의 통계량을 이용하여 모집단의 모수를 추정하거나 모수에 대한 가설을 검정하는 데에 사용하는 통계

모집단

표본추출

표 본

추론통계

모 수

모집단의 특성을 나타낸 값 or 수치화한 값

통계량

표본집단의 특성을 나타낸 값 or 수치화한 값

통계(statistics)

기술통계(descriptive statistics)

- 자료를 적절하게 그림, 도표 또는 수치로 특성을 요약하고 기술하는 통계

추론통계(inferential statistics)

- 모집단으로부터 추출한 표본의 통계량을 이용하여 모집단의 모수를 추정하거나 모수에 대한 가설을 검정하는 데에 사용하는 통계

표본추출

기술통계

추론통계

모수(parameter) ← 추정 및 가설검정 — 통계량(statistic)

- 모집단의 구성원 모두를 측정하여 얻을 수 있는 모집단의 특성을 나타내는 값
  예) μ, σ^2, σ

- 표본의 관측치를 측정하여 얻은 값으로써 표본의 특성을 나타내는 값
  예) $\bar{x}$, S^2, S

- 특정한 표본의 통계량값을 통계치라 함

통계량(표본평균)		통계치
$\bar{x}$	=	172.5

◆ 통계 분석의 목적 : 설명, 예측, 통제

▪설명 (Experience) : 현상을 기술 설명한다는 의미 –현상이 발생되는 원인을 설명

학업성취도

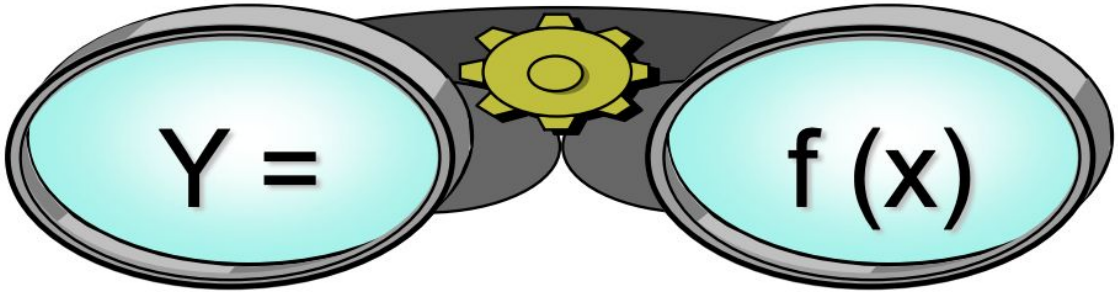

공부시간

과목흥미도

지적 수준

•예측 (Prediction) : 설명에 의거한 예측이 가능 예) 주가, 경제 지표, 수요량

•통제 (Control) : 투입량을 조절을 통하여 산출량 통제 예) 각종 원재료의 투입량과 산출량

기술통계

기술통계	자료를 적절하게 그림이나 도표 또는 수치로 요약하여 기술함으로써 자료를 의사결정을 위한 정보로 바꾸는 데에 활용하는 통계

기술통계의 정의

- 자료를 적절하게 그림이나 도표 또는 수치로 요약하여 기술함으로써 자료를 의사결정을 위한 정보로 바꾸는 데에 활용되는 통계를 말함

년,월	도매	소매	총매출액(Y)
2004,1	47,300	125,365	172,656
2004,2	46,100	61,888	107,988
2004,3	202,425	159,438	361,863
2004,4	235,400	81,800	317,200
2004,5	199,750	68,134	267,884
2004,6	281,000	59,763	340,763
2004,7	532,550	34,320	566,870
2004,8	184,315	75,806	260,121
2004,9	280,950	65,816	346,766
2004,10	428,840	50,937	479,777
2004,11	391,820	83,146	474,966
2004,12	744,790	90,143	834,933
총합	3,575,240	956,547	4,531,787
평균	297,937	79,712	377,649

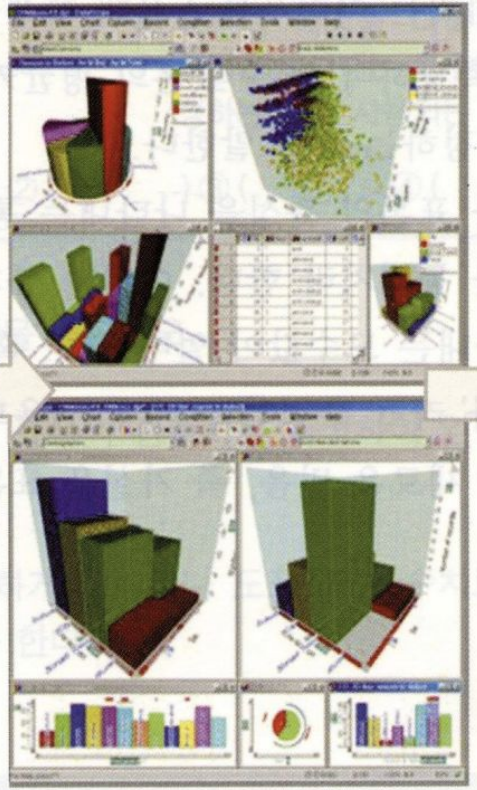

추론통계

추론통계	표본의 특성을 나타내는 통계량으로 모집단의 특성을 나타내는 모수를 추정하거나 모수에 대한 가설을 통계량으로 검정하는 데에 사용되는 추론통계라 함

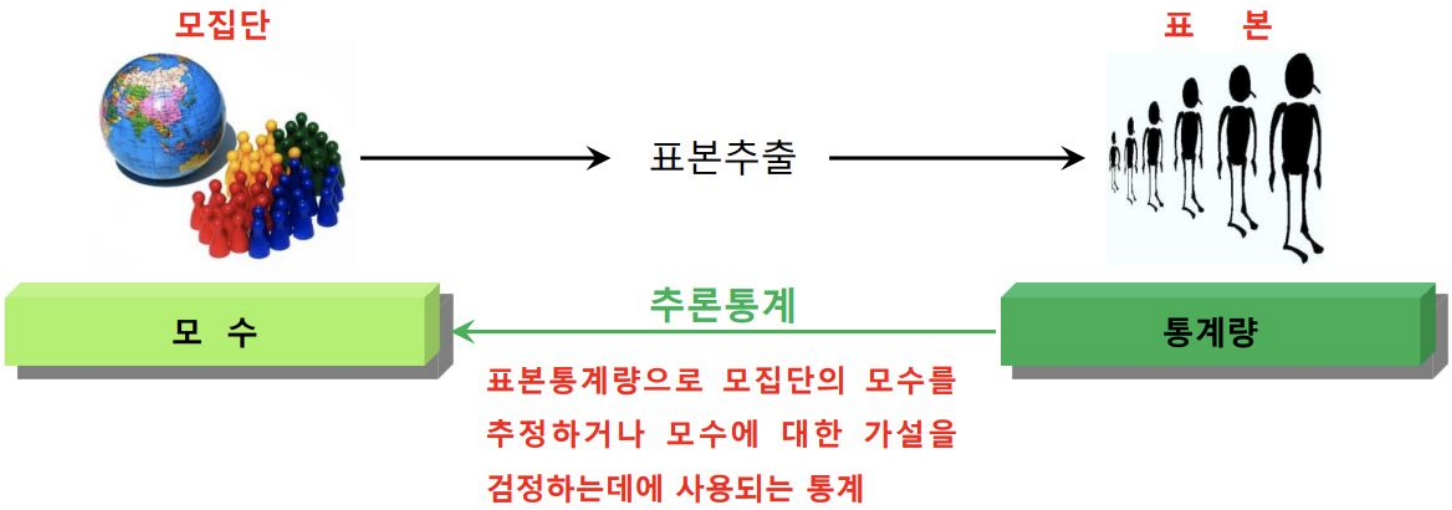

추론통계의 정의

- 표본의 특성을 나타내는 통계량으로 모집단의 특성을 나타내는 모수를 추정하거나 모수에 대한 가설을 통계량으로 검정하는 데에 사용되는 통계를 추론통계라 함

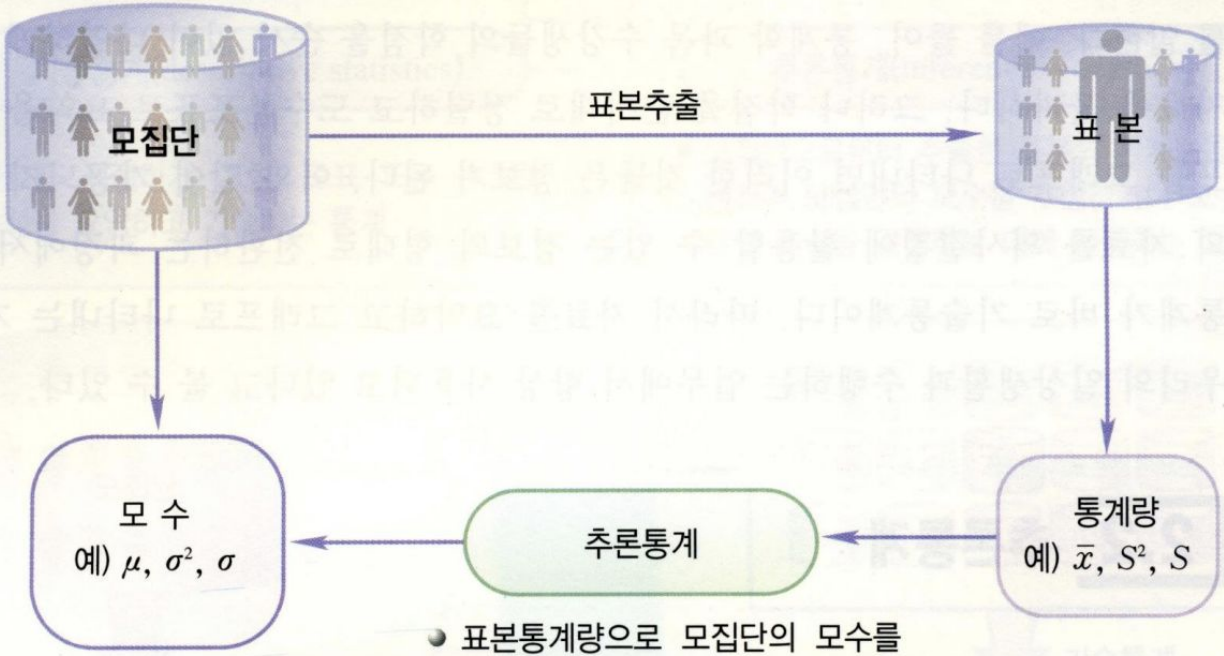

- 표본통계량으로 모집단의 모수를 추정하거나 모수에 대한 가설을 검정하는 데에 사용되는 통계

자료수집과정

분석 문제의 결정

대상의 선정

관심속성의 결정

척도의 선정

측 정

결과값을 변수에 축적

자료

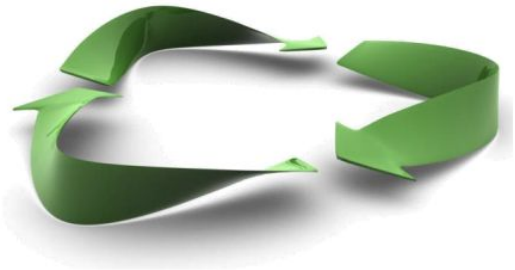

질적자료

- 성별
- 안경착용유무
- 직업, 체온(낮다,높다)

척도선택

명목척도

서열척도

등간척도

비율척도

자료의 측정

- 관찰을 통한 성별 파악
- 안경착용 유무의 관찰
- 온도계를 통한 체온 측정
- 줄자를 이용한 키의 측정

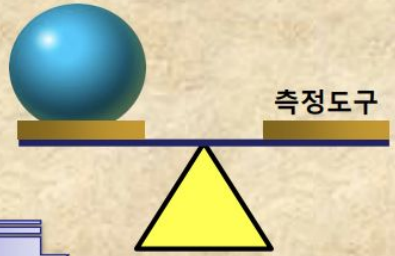

양적자료

- 변수 : 이산변수와 연속변수
- 상수

측정

측정의 정 의	· 관찰대상이 가지고 있는 **특성**에 대해서 일정한 규칙에 따라 기술적으로 수치를 부여함으로써 **계량화**하는 것을 의미함. · 개체가 가지고 있는 속성을 관찰하여 **변수 값으로 표현**하는 것을 의미함.

관심대상 선정 → 관심속성 파악 → 수집방법 결정 → 측 정 → 측정값 기록

척도

척도의 정 의

· 관찰대상의 속성을 측정하여 그 값을 숫자로 나타내는 **일정한 규칙**으로서 **질적자료를 양적자료로 변환**시키는 데에 사용하는 도구

질적자료

척도측정

얼마나
아름다운가?
키는?

양적자료

참가자	미의정도	키
1	5	172
2	3	168
3	4	163
4	5	170
5	2	167
6	4	169

척도의 종류

질적변수

질적척도

- 명목척도
- 서열척도

- 관찰대상의 관심속성을 측정하여 그 값을 범주로 나타냄.
- 모든 연산이 불가능함 예) 남/여

- 관찰대상의 관심속성을 측정하여 그 값을 순위로 나타냄.
- 모든 연산이 불가능함 예) 1등, 2등, 3등

양적변수

양적척도

- 등간척도
- 비율척도

- 관찰의 대상의 속성값을 상대적 크기로 나타냄.
- 사직연산 중에 가감만이 가능함
- 예) 온도, 5점 척도(만족도, 중요도)

- 절대적 기준인 영점이 존재하고 모든 사칙연산이 가능함.
  예) 키, 몸무게

명목척도

· 관찰대상의 속성에 따라 **관찰대상을 상호 배타적이고 포괄적인 범주로 구분**하는 수치를 부여하는 도구

· 명목척도로 측정된 변수 간의 **사칙연산은 의미가 없음.**

예) 운동선수의 등 번호, 학번

13 + 50

= 63

서열척도

· 관찰대상이 가지고 있는 **속성의 크기에 따라 관찰 대상의 순위를 나타내는 수치**를 부여하는 측정 도구

· 상대적인 순위만 구분할 뿐, 서열간의 차이는 중요하지 않음

예) 2010년 벤쿠버 올림픽 (올림픽에서는 기록보다 순위가 더 중요 함.)

등간척도

· 관찰대상이 가지고 있는 **속성 크기의 순서뿐 아니라 상대적인 차이**도 고려하여 측정하는 도구

· 관찰대상이 가지고 있는 속성 크기의 양적 차이를 특정하기 위해서 **등간격으로 분할**한 척도를 사용

· 관찰대상이 가지고 있는 **속성 크기의 차이**는 절대적 기준이 없어 **상대적인 차이**로만 나타남.

· 등간척도로 측정된 변수들 간의 가감 연산이 가능함 / 예) 리커트 5점, 7점 척도

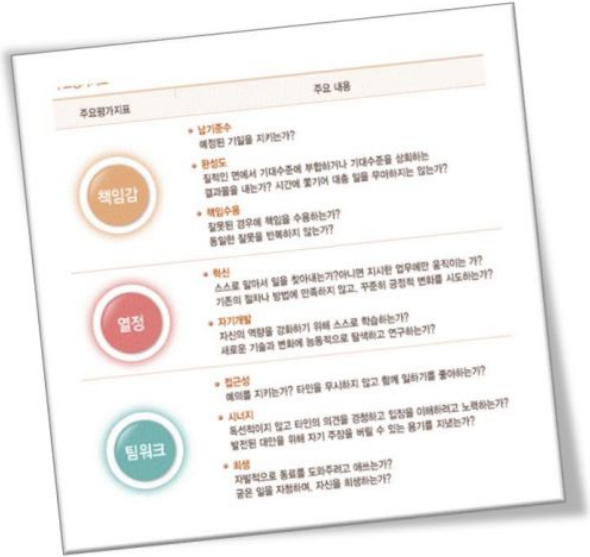

비율척도

· 등간척도에 비율의 개념이 추가된 척도로서 **절대적 기준 값이 존재**하는 척도

· 수치상 가감승제와 같은 모든 **산술적인 사칙연산**이 가능함

예) 해수면을 기준으로 하는 산의 높이, 몸무게, 키 등

한라산의 높이가 1,950m이고, 백두산의 높이가 2,750m라는 것은 해수면이라는 절대적인 기준점에서부터의 높이임.

척도의 특징

· **명목척도에서 비율척도**로 척도의 수준이 높아질수록 변수가 내포하고 있는 **정보의 양이 증가**함

· 척도의 **수준이 높아질수록** 자료수집에 필요한 비용과 노력이 많이 소요됨.

· 변수측정에 필요한 비용이나 노력, 그리고 변수가 갖는 정보량은 서로 비례함.

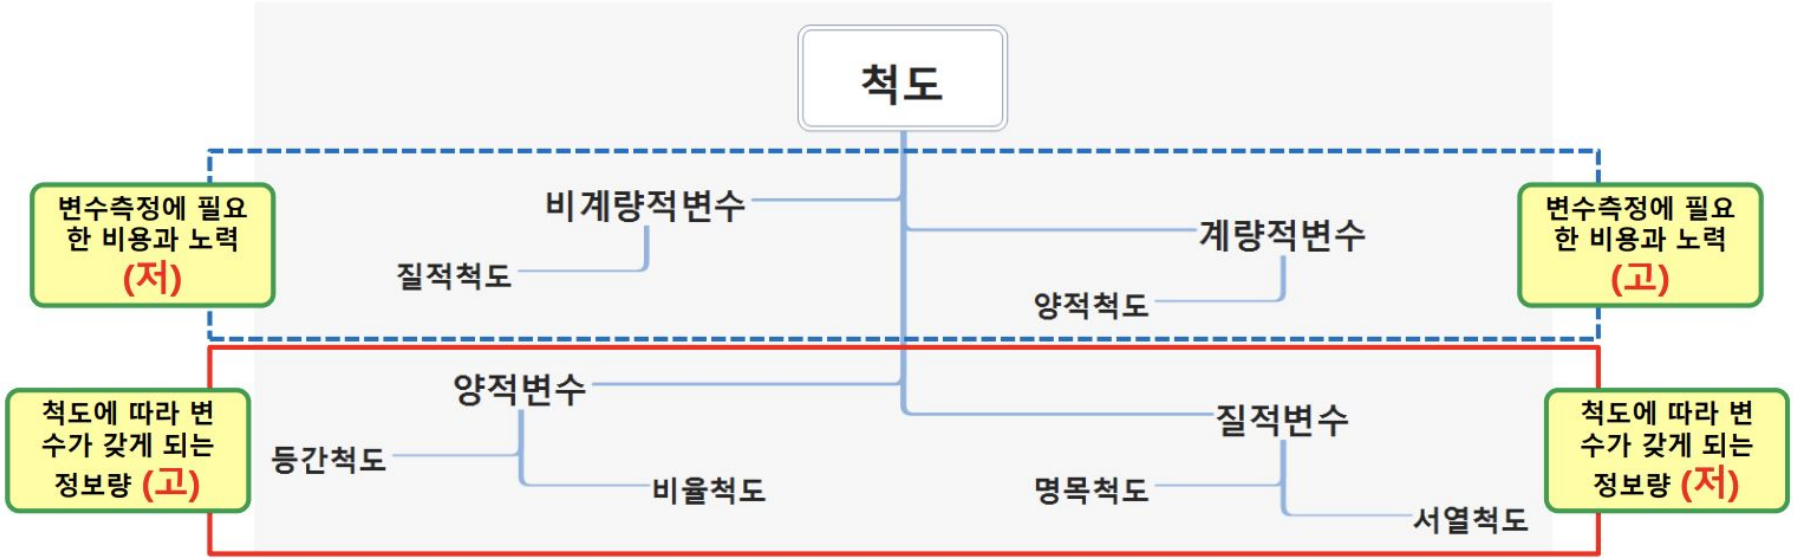

변수의 종류

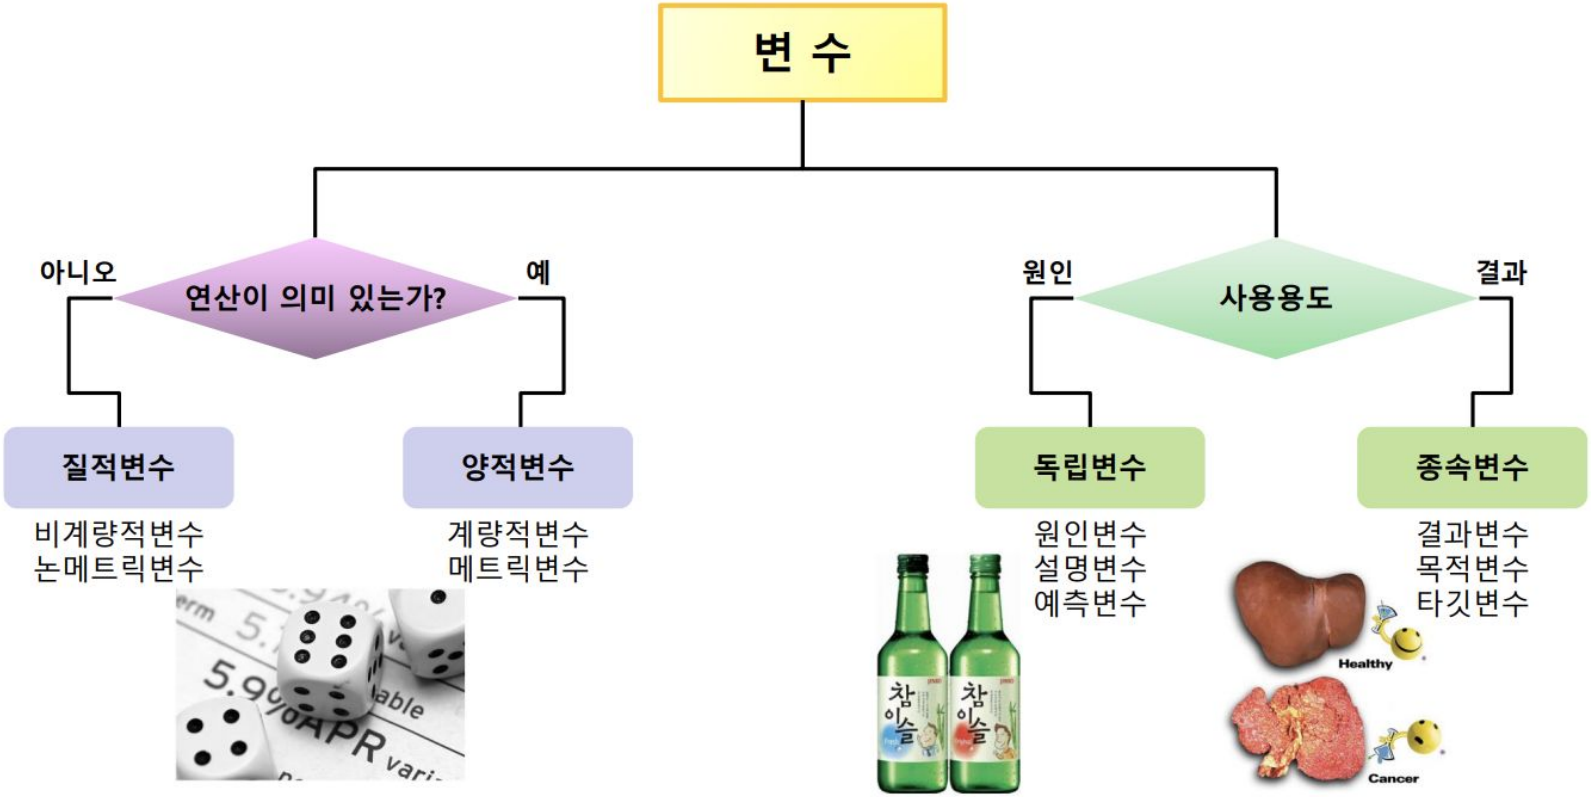
변 수
연산이 의미 있는가?
아니오
예
질적변수
양적변수
비계량적변수
논메트릭변수
계량적변수
메트릭변수
사용용도
원인
결과
독립변수
종속변수
원인변수
설명변수
예측변수
결과변수
목적변수
타깃변수
Healthy
Cancer

연속형 변수 (Continuous Variable)

정의

이론적으로 무한히 세분 가능한 값을 가지는 변수

핵심 특성

- 값과 값 사이에 **항상 다른 값이 존재**
- 측정 오차를 전제로 함
- 실수(real number) 개념

예시

- 키 (170.35 cm)
- 몸무게 (65.2 kg)
- 시간 (3.47초)
- 온도 (22.8°C)

통계적 특징

- 평균, 분산, 표준편차 계산에 자연스럽게 사용
- 정규분포 가정이 자주 등장
- 적분 개념과 연결됨 (확률밀도함수)

중요 포인트

연속형 변수에서는 **정확히 어떤 값이 나올 확률은 0**이다.
대신 **구간에 속할 확률**을 다룬다.

이산형 변수 (Discrete Variable)

정의

셀 수 있는 값만 가지는 변수

핵심 특성

- 값 사이에 중간값이 없음
- 대부분 **정수 값**
- 사건의 발생 횟수 표현에 적합

예시

- 자녀 수 (0, 1, 2, 3)
- 하루 방문 고객 수
- 불량품 개수
- 동전 앞면 횟수

통계적 특징

- 확률질량함수(PMF) 사용
- 정확한 값에 확률이 존재
- 이항분포, 포아송분포 등과 연결

중요 포인트

이산형 변수에서는
"정확히 3이 나올 확률"이 의미를 가진다.

구분	연속형 변수	이산형 변수
값의 형태	실수	정수
중간값 존재	항상 존재	없음
확률 개념	구간 확률	값 자체 확률
분포 함수	확률밀도함수(PDF)	확률질량함수(PMF)
예시	키, 몸무게	개수, 횟수

연속형 변수 데이터 처리 시 주의점

(1) 임의 구간화(bin) 남용 금지

- 연속형을 구간으로 나누면 정보가 손실됨
- 예: 키를 `160~170` / `170~180`으로 나누는 순간
  → **미세한 차이 소멸**

원칙

구간화는 해석을 위한 도구이지, 분석의 출발점이 아니다.

(2) 이상치(outlier) 제거는 이유가 있어야 한다

- 연속형은 이상치에 민감
- 무조건 제거 ❌

확인해야 할 것:

- 측정 오류인가?
- 실제로 의미 있는 극단값인가?

핵심 사항

이상치는 제거 대상이 아니라, 질문의 대상이다.

(3) 스케일 차이 무시 금지

- 연속형 변수 간 단위 차이 존재
- 거리 기반 모델(KNN, SVM, 회귀)에 영향 큼

✔️ 표준화(Z-score)
✔️ 정규화(Min-Max)

(4) 분포 형태 무시 금지

- 비대칭 분포에서 평균 해석 주의
- 로그 변환, Box-Cox 고려

이산형 변수 데이터 처리 시 주의점

(1) 숫자라고 해서 연속형처럼 다루지 말 것

- 이산형은 “크기”보다 “개수/발생” 의미
- 평균이 항상 의미 있지는 않음

예:

- 자녀 수 평균 = 1.3명 (해석 주의)

(2) 희소성(sparsity) 문제

- 이산형 카운트 데이터는 0이 많음
- 단순 평균은 왜곡 가능

✔️ 포아송 / 음이항 모델 고려

(3) 범주형과 혼동 주의

- 이산형 ≠ 범주형
- 0,1,2가 **순서/크기 의미가 있는지** 확인 필요

예:

- 신용등급(1~10) → 숫자지만 범주형 성격 강함

(4) 분포 가정 확인

- 이항, 포아송 등 분포 가정에 민감
- 과산포(overdispersion) 체크 필수

통계 / ML / DL / LLM

통계 (Statistics)

핵심 질문

“왜 이런 결과가 나왔는가?”

사고 방식

- 데이터는 **현상의 일부(표본)**
- 가정을 세우고 검증
- 불확실성을 수치로 관리

특징

- 설명 가능
- 적은 데이터에도 강함
- 정책·의사결정 근거로 사용

예시

- “소득이 높을수록 연체 확률이 낮은가?”
- “이 효과는 우연이 아닌가?”

→ **통계는 ‘판단의 책임’을 다루는 학문**

머신러닝 (ML)

핵심 질문

“미래를 얼마나 잘 맞출 수 있는가?”

사고 방식

- 데이터에서 패턴을 직접 학습
- 가정 최소화
- 성능 중심 평가

특징

- 예측 정확도 높음
- 구조를 몰라도 동작
- 설명력은 약함

예시

- “이 고객은 연체할 확률이 높은가?”
- “다음 달 수요는 얼마인가?”

→ **ML은 ‘맞추는 능력’을 최적화하는 기술**

딥러닝 (DL)

핵심 질문

“이 복잡한 데이터를 어떤 표현으로 바꾸면 잘 맞출까?”

사고 방식

- 특징(feature)을 사람이 설계 ❌
- 표현을 모델이 스스로 학습
- 대규모 데이터 전제

특징

- 비정형 데이터에 강함
- 블랙박스 성향 강화
- 계산 자원 의존

예시

- 이미지 속 물체 인식
- 음성 → 텍스트
- 문장 감정 분류

📌 **DL은 ‘표현 학습’의 혁명**

LLMs (Large Language Models)

핵심 질문

“이 맥락에서 다음에 와야 할 행동은 무엇인가?”

사고 방식

- 언어를 확률적 구조로 학습
- 지식 + 패턴 + 맥락 결합
- 추론처럼 보이는 생성

특징

- 범용성
- 맥락 이해 능력
- 인간과 협업 가능

예시

- 질문에 답변
- 코드 작성
- 요약·추론·설명

📌 **LLM은 ‘도구를 쓰는 지능’에 가까움**

구분	통계	ML	DL	LLM
핵심 질문	왜?	얼마나 잘?	어떻게 표현?	다음은?
가정	명시적	최소	거의 없음	없음
설명 가능성	높음	낮음	매우 낮음	언어적 설명 가능 (하지만 근본은 확률)
데이터 규모	작아도 가능	중간	매우 큼	초대형
대표 역할	판단 근거	예측 엔진	인식 엔진	사고 보조

사람들이 가장 많이 오해하는 지점

❌ **“ML/DL이 통계를 대체했다”**

→ 아니다. 질문이 다르다.

❌ **“LLM은 이해하고 생각한다”**

→ 아니다. 맥락 속 확률적 생성이다.

❌ **“정확하면 좋은 모델이다”**

→ 아니다. 책임질 수 있어야 좋은 모델이다.

통계는 인간의 책임을 전제로 하고,
ML은 인간의 판단을 자동화하며,
DL은 인간의 인식을 흉내 내고,
LLM은 인간의 사고 과정을 인터페이스로
만든다.

Q & A