예측 문제 정의: 회귀 vs 분류

금융 데이터 분석의 첫 단계는 비즈니스 문제를 머신러닝 문제로 치환하는 것입니다.

예금 잔액 예측 (회귀)

미래 시점의 연속적인 숫자(잔액)를 예측합니다.

- 지점별 현금 보유량 최적화
- VIP 고객 자산 이탈 징후 포착

연체 여부 예측 (분류)

고객이 정상(0) 또는 연체(1)할지 이산적 클래스를 예측합니다.

- 신용평가모형 개발
- 대출 심사 자동화

회귀 평가 지표

RMSE: 오차 크기 중점

MAE: 이상치에 덜 민감

MAPE: 오차 비율로 설명

분류 평가 지표

AUC-ROC: 불균형 데이터 변별력

Recall: 연체자 탐지 중요

KS Statistic: 금융권 전통 지표

파이프라인

금융 모델링 파이프라인

금융 데이터는 노이즈가 많고 분포가 치우쳐 있으며, 결측치의 의미가 중요합니다.

01

탐색적 데이터 분석 (EDA)

변동 데이터는 Log-normal 분포를 따르므로 Log 변환을 고려합니다. 결측치가 단순 누락인지 "해당 상품 없음"을 의미하는지 해석이 필요합니다.

02

Feature Engineering

모델링 성능의 80%를 결정합니다. DTI, 한도 소진율 등 비율 변수와 최근 3개월 평균 대비 변동 변수를 생성합니다.

03

모델링

Tree-based Ensemble(XGBoost, LightGBM)이 표준입니다. 비선형 관계 포착과 결측치 자동 처리가 가능합니다.

04

평가 및 해석

Lift Chart로 타겟팅 효과를 시각화하고, SHAP Values로 변수 기여도를 설명합니다.

파생변수 예시

비율 변수: DTI, 한도 소진율

변동 변수: 최근 3개월 평균 대비 사용액

RFM: 최근 대출 시기, 대출 횟수

WOE & IV: 범주형 변수 변환 및 필터링

핵심 알고리즘 비교

LightGBM vs XGBoost

특징	XGBoost	LightGBM
트리 성장 방식	Level-wise (균형 중심) 과적합 방지에 유리	Leaf-wise (리프 중심) 정확도 높으나 과적합 주의
속도	상대적으로 느림	매우 빠름
메모리 사용	많음	적음
추천 상황	데이터가 적거나 안정성 최우선	1만 건 이상 대용량 데이터

현업 Tip: 금융 현업에서는 두 모델을 모두 실행하여 앙상블하거나, 실시간 승인 시스템에는 LightGBM을 선호합니다.

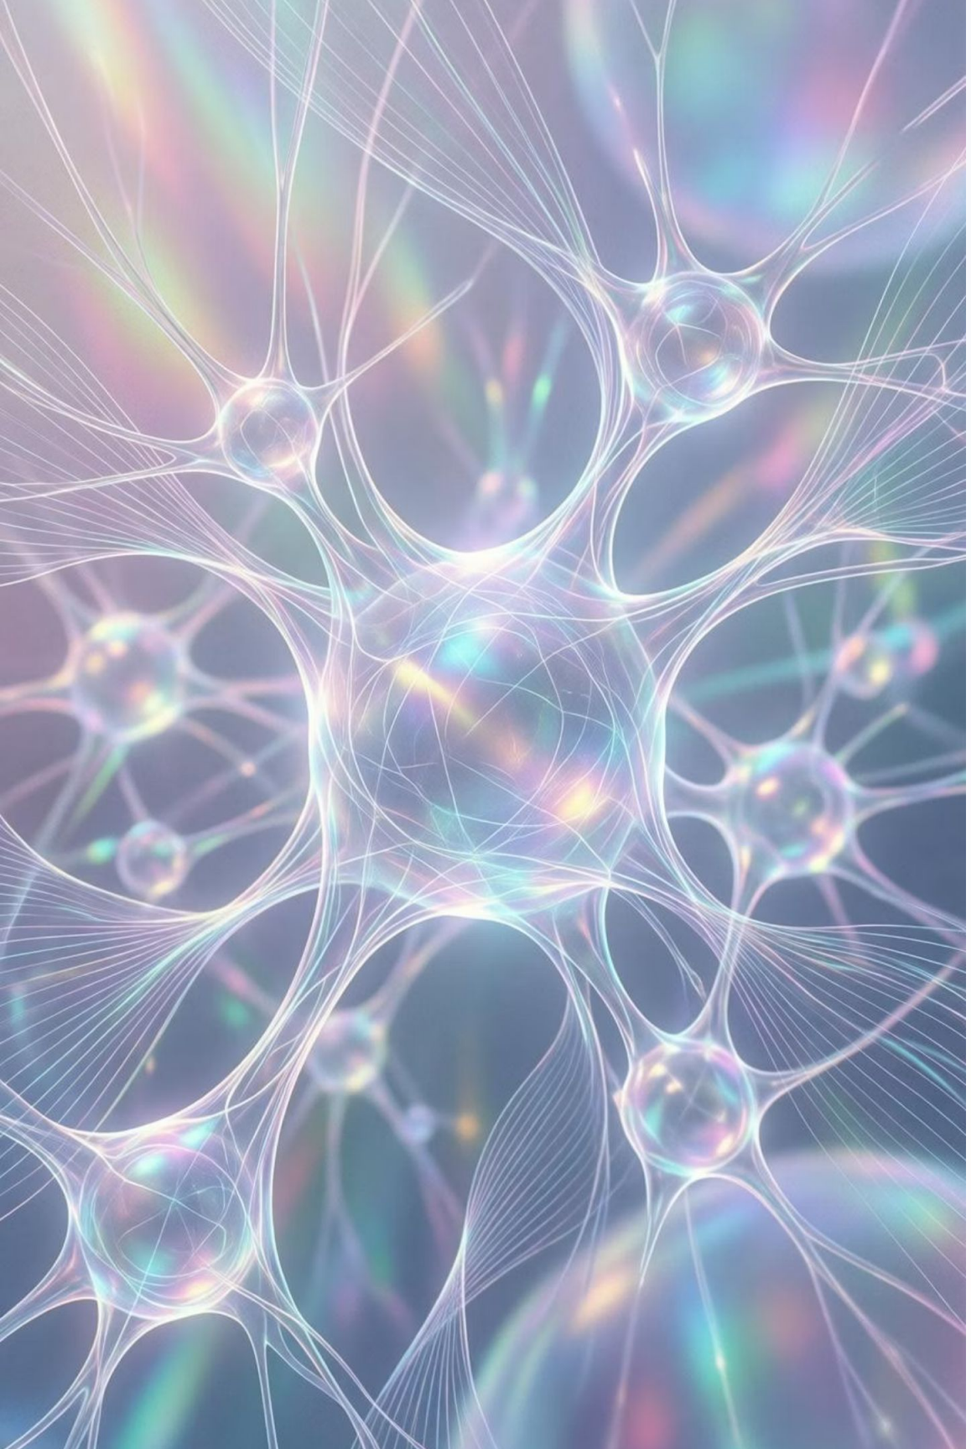

실습

신용카드 연체 예측 실습

데이터셋

UCI Default of Credit Card Clients Dataset

(대만 신용카드 연체 데이터)

인구통계 정보와 과거 6개월간 청구액 및 납부 이력을 포함하며, 다음 달 연체 여부를 예측합니다.

불균형 데이터 처리

연체자가 매우 적으므로 scale_pos_weight 파라미터 설정 또는 SMOTE 오버샘플링 적용

하이퍼파라미터 튜닝

max_depth, learning_rate, n_estimators 조정 및 Early Stopping으로 과적합 방지

Feature Importance

연체에 가장 큰 영향을 미친 변수 확인 (예: PAY_0 전월 상환 이력)